

AI for Research | 虚拟细胞方向

面向未知条件泛化的 虚拟酵母扰动蛋白质组响应预测

基于稳定核心模型与分场景残差专家的方法

参赛队伍：小米蕉队

初赛技术方案：科学问题、方法设计、实验验证与后续研究路线。

目录

- 1 项目概述 1
 - 1.1 项目名称 1
 - 1.2 参赛队伍 1
 - 1.3 参赛方向 1
 - 1.4 方案概述 1
- 2 科学问题理解 2
 - 2.1 科学问题与研究对象 2
 - 2.1.1 虚拟细胞与本赛题边界 2
 - 2.1.2 为什么选择酿酒酵母 3
 - 2.1.3 核心科学问题 3
 - 2.1.4 OOD 泛化场景 4
 - 2.2 科学意义 4
- 3 技术方案与方法路线 4
 - 3.1 技术方案 5
 - 3.1.1 数据合同与预处理 5
 - 3.1.2 评价指标：同时衡量终点、响应和个性 6
 - 3.1.3 从 baseline 到 OOD 路由模型 7
 - 3.2 扩展研究路线 10
 - 3.2.1 从 RNA 扰动预测迁移的方法 10
 - 3.2.2 受条件控制的低维蛋白动态模拟器 11
 - 3.2.3 条件化预测分布与不确定性旁路 12
 - 3.2.4 开放知识与实体 encoder 12
 - 3.2.5 RAG、候选机制链与可选 LoRA 13
 - 3.3 数据来源、依赖工具与运行流程 14
- 4 实验结果与可行性验证 14
 - 4.1 基线与数据特性 14
 - 4.1.1 平均值 baseline：高总体相关不等于条件响应 15
 - 4.1.2 Metadata Ridge 与批次消融 15
 - 4.2 模型比较与泛化结果 16
 - 4.2.1 已通过或有限通过的 OOD 分支 16
 - 4.2.2 低维动态模型小规模验证：递归状态未带来额外收益 17
 - 4.2.3 Grouped rolling-origin：真实前缀有效，递归仍未胜出 17
 - 4.2.4 静态前缀确认实验：只改善未来变化，不改善绝对响应 18
 - 4.2.5 多目标损失与高响应蛋白验证 19
 - 4.2.6 公平条件架构对比：仅使用条件 metadata 的 MLP 未超过 Ridge 20
 - 4.2.7 外部公共知识 Transformer：结构覆盖子集呈现弱信号，全实体主分析未晋级 21
 - 4.2.8 公共蛋白知识表征聚类 multi-head：完整条件留出中神经模型改善，但分组无增量价值 22
 - 4.2.9 命名酵母 GO-slim：正确通路归属出现局部信号，但未超过简单模型 22
 - 4.2.10 药物靶点到 STRING 局部网络：当前实现未通过严格 OOD 门槛 23
 - 4.2.11 真实菌株变异与 CNV：LoF/移码存在可信弱信号但未晋级 24
 - 4.2.12 缺失阈值与实测对照校准 24
 - 4.2.13 未通过的候选同样定义了研究边界 26

4.2.14	不确定性有局部价值，但不能牺牲点预测	26
4.2.15	公开数据实验的正向证据与限制	27
4.2.16	消融验证对技术方案的影响	27
4.2.17	最终模型路由与研究结论	29
5	复现、开放与合规	30
5.1	复现方式	30
5.2	代码索引与复现边界	31
5.3	开放与交付	34
5.4	数据与模型合规	34

1 项目概述

1.1 项目名称

面向未知条件泛化的虚拟酵母扰动蛋白质组响应预测：基于稳定核心模型与分场景残差专家的方法。

1.2 参赛队伍

小米蕉队

1.3 参赛方向

GOAI AI for Research 算法赛题——虚拟细胞方向，具体任务为酿酒酵母扰动蛋白质组响应预测。

方案设置封闭数据与开放知识两套独立配置。封闭配置仅使用组委会提供的数据与允许字段；开放配置额外接入公开化合物结构、菌株基因组、酵母知识库和公开组学，并逐项记录来源、许可与消融结果。两套配置共享相同的输出合同和 OOD 评价体系，外部特征及其派生统计不进入封闭配置。

1.4 方案概述

本方案遵循“先固定数据合同与评价体系，再逐步增加模型复杂度”的研究顺序。首先完成输入、输出、缺失处理和 **OOD (out-of-distribution, 分布外泛化)** 划分，并定义能够区分“基础蛋白谱预测”与“条件特异响应预测”的指标。受到 Systema 对系统性变化和平均响应陷阱的分析启发 [5]，方案以每蛋白训练均值作为最低基线，进一步要求模型同时提高：（1）处理样本相对于匹配溶剂对照的变化预测；（2）特定药物或菌株相对于共享响应的残差预测；（3）不同实验条件之间的个性化差异预测；并降低均方根误差（RMSE）。

第二步仅使用比赛提供的实验条件字段训练岭回归模型（Ridge），作为稳定核心基线，并分别在未见菌株、未见化合物、双重未知和时间留出场景中验证。随后针对不同场景构建低秩残差、时间轨迹、条件神经网络和校准分支；候选分支只有在预先设定的多指标门槛上稳定优于核心基线时才进入最终路由。

若推理流程额外提供同条件实测溶剂对照，可启用成对实测对照校准分支。处理与对照必须在相同的有效重复样本对上聚合；缺少该输入时关闭。该方法在预先得限定的成对估计口径下获得稳定增益，但对聚合定义敏感，因此只作为有实测对照时的条件校准，不属于默认预测分支。

第三步参考单细胞 RNA 扰动预测中的潜空间建模、条件自编码器和图结构先验 [6, 7, 14, 8]。低维表示可由 PCA/SVD[9, 10]、自编码器 [11, 7]、VAE[12, 6] 或图神经网络 [13, 8] 获得。RNA 模型迁移将比较结构复用、冻结 encoder 加轻量适配器和折内微调三种方式；时间建模则比较静态条件网络、线性状态空间、LSTM/GRU 与 Latent ODE[15, 16, 17]。所有候选均在相同 OOD 划分、输出面板和掩码规则下与 Ridge 及线性低秩模型比较。

开放知识配置进一步引入 ChEBI 化合物结构以及 GO、Reactome 和 STRING 蛋白知识。首

轮知识增强 Transformer 在结构已覆盖的药物子集上出现局部信号，但将有映射与未映射药物全部纳入的主分析未超过 Ridge，公共蛋白摘要也未通过消融，因此暂不扩展至完整蛋白面板。功能模块实验进一步比较同容量单头、正确分组多头和保持组大小的错配多头；匿名分组未带来稳定增益。随后构建的命名 GO-slim 多标签通路模型在整种药物未知场景中仅相对通路归属置换对照出现弱增益，仍未超过 Ridge 或同容量单头，在未见 K_{bio} 组合中也未形成可归因收益。输入侧的 STITCH 靶点到 STRING 局部网络分支也已完成全实体主分析：当前映射仅覆盖训练集中的 14/37 个药物，且两类 OOD 的 Raw-FC 均低于直接 Ridge，未通过网络错配负对照。因此，上述知识分支均不进入当前路由；该结论只否定当前稀疏映射与编码实现，不否定药物靶点知识的一般价值 [28, 27]。

菌株输入侧进一步使用 Peter 等 (2018) 的公开菌株功能缺失 (LoF)、移码、基因存在/缺失与拷贝数构造命名 GO 通路负担 [21]。五通道联合分支和 CNV/基因存在性分支未通过；LoF/移码分支在与探索面板零重叠的独立确认面板上使整株留出全实体主分析的 Raw-FC PCC 提高 +0.007003。正确菌株身份在六种分配中排名第一，但只有 2/3 个已覆盖菌株的折增益为正，且 RMSE 增加 +0.001107。因此，该结果构成可信但尚不稳定的菌株侧信号，暂不进入正式路由。

机制知识路线采用本地 RAG 与开放权重语言模型，将公共酵母蛋白质组、化合物结构与靶点、菌株变异与 CNV，以及 SGD、GO、YeastPathways、STRING 和公开文献整理为可追溯知识库 [22, 21]。给定药物、菌株、培养基、温度和时间，模型生成“候选靶点或过程 → 通路 → 蛋白网络或功能模块 → 候选响应”的结构化机制特征；最终响应方向和幅度仍由训练折内的实测蛋白数据监督学习。验证分别完整留出药物、菌株及二者组合，并与基础模型、随机特征和实体错配负对照比较。

不含 RAG 的双模型诊断中，Qwen3 8B 与 Gemma 12B 的预训练知识机制特征在五折 whole-drug OOF 中降低 Raw-FC 并增大 RMSE，表明仅依赖模型参数中的药物名称知识不足以支持新药泛化。后续将以可追溯检索证据和可泛化实体表示为前提，再评估 RAG 与 LoRA。




图 1: 总体方案路线。绿色表示已经完成验证的模块，黄色表示后续研究模块；所有候选均以严格 OOD 结果决定是否进入最终模型。

2 科学问题理解

2.1 科学问题与研究对象

2.1.1 虚拟细胞与本赛题边界

虚拟细胞是一类利用计算模型表示细胞状态、模拟细胞过程并预测细胞在遗传、化学或环境变化下行为的研究体系。它经历了机制方程驱动的可计算细胞、整细胞集成模型以及近年来的数

据驱动 AI 模拟器等阶段 [1, 2]。本赛题并不要求完整模拟 DNA 复制、RNA 转录、翻译、代谢和细胞分裂，而是聚焦虚拟细胞中的一个可量子化任务：**条件化酵母总蛋白质组扰动响应预测**。

对样本 i ，生物条件记为

$$\mathbf{x}_i = (s_i, d_i, m_i, T_i, t_i), \quad (1)$$

其中 s_i 为菌株， d_i 为化合物或 vehicle/control， m_i 为培养基， T_i 为温度， t_i 为处理时间。模型输入还可以包含允许使用的测量环境字段 $\mathbf{e}_i$ ，输出为固定蛋白面板的预测：

$$\hat{\mathbf{y}}_i = f_{\theta}(\mathbf{x}_i, \mathbf{e}_i) \in \mathbb{R}^{5243}. \quad (2)$$

这里的不同菌株主要代表不同**遗传背景**，不能等同于标准化单基因敲除；输出是总蛋白丰度，也不能等同于 RNA 表达、磷酸化位点、酶活性或代谢通量。RNA、通路和代谢信息可以作为先验或中间表示，但本赛题最终仍需输出蛋白质组。

2.1.2 为什么选择酿酒酵母

酿酒酵母在复杂性和可验证性之间提供了少见平衡。它是真核生物，具有细胞核、线粒体、内质网、高尔基体和液泡等区室；同时生长快、培养和遗传操作成熟，具有系统性的删除库、GFP 定位库、遗传互作图谱及 *Saccharomyces* Genome Database (SGD) 等知识资源 [18, 19, 20, 22]。此外，1,011 株酿酒酵母 isolates 的全基因组资源揭示了 SNP、结构变异、拷贝数变化、倍性与非整倍体，为跨遗传背景建模提供了现实基础 [21]。

但公共资源与比赛标签之间并非等价关系。例如，基因敲除适应度不等于药物诱导的蛋白丰度变化，STRING 关联分数不等于调控方向，蛋白丰度也不等于代谢通量。因此，生物知识只能作为待验证的结构先验，不能代替 OOD 实验。

2.1.3 核心科学问题

本项目将科学问题表述为：

在有限、稀疏且组合不完整的酵母扰动蛋白质组数据上，能否学习化合物、遗传背景、培养环境与时间之间的组合规律，并在未见化合物、未见菌株及二者同时未知时，预测完整蛋白面板及其条件特异变化？

原始正值质谱强度 $I_{i,p}$ 对有效观测取

$$y_{i,p} = \log_2 I_{i,p}. \quad (3)$$

令 $M_{i,p} \in \{0, 1\}$ 表示该观测是否存在，则最基础的 masked loss 为

$$\mathcal{L}_{\text{end}} = \frac{\sum_{i,p} M_{i,p} (y_{i,p} - \hat{y}_{i,p})^2}{\sum_{i,p} M_{i,p}}. \quad (4)$$

然而终点蛋白谱包含稳定基础丰度、真实扰动响应和测量环境效应：

$$\mathbf{y}_i = \mathbf{b}_i + \mathbf{\Delta}_i + \boldsymbol{\gamma}_i + \boldsymbol{\varepsilon}_i. \quad (5)$$

其中 $\mathbf{b}_i$ 是背景蛋白谱, Δ_i 是希望学习的条件特异响应, γ_i 是来源或仪器等批次效应。因此, 一个只预测 $\mathbf{b}_i$ 的模型也可能获得很高总体相关性, 却没有学会药物或菌株个性。这正是本项目首先检验平均值 baseline 的原因 [5]。

2.1.4 OOD 泛化场景

令训练中出现的菌株和化合物集合分别为 $\mathcal{S}_{\text{tr}}$ 和 $\mathcal{D}_{\text{tr}}$ 。四类主要场景为:

表 1: 四类主要 OOD 场景

场景	数学条件	需要的能力
未见菌株	$s_i \notin \mathcal{S}_{\text{tr}}, d_i \in \mathcal{D}_{\text{tr}}$	将已见药物规律迁移到新遗传背景。
未见化合物	$s_i \in \mathcal{S}_{\text{tr}}, d_i \notin \mathcal{D}_{\text{tr}}$	由结构、靶点或公共知识推断新药响应。
双重未知	$s_i \notin \mathcal{S}_{\text{tr}}, d_i \notin \mathcal{D}_{\text{tr}}$	同时组合两个未见实体的表示。
时间留出	基础条件已见, 但目标时间未在该条件训练数据中出现	学习同一条件的响应轨迹; 区分时间插值与真正外推。

此外, “菌株和药物分别见过, 但它们的组合从未见过”属于 pair-OOD。它考察组合补全, 不能冒充未见药物或双重未知。所有重复、剂量和完整培养条件必须按 condition identity 成组留出, 避免同一实验条件的重复一部分进入训练、另一部分进入验证。

后续实验还使用两个更严格的分组简称: **whole-chemical** 表示将一种化合物的全部条件整体留出; **whole- K_{bio}** 表示将完整生物条件

$$K_{\text{bio}} = (\text{菌株}, \text{化合物}, \text{培养基}, \text{温度})$$

整体留出, 其组成菌株和化合物仍可能分别出现在训练集中。后者检验完整条件组合的泛化, 不等同于“新菌株”或“新药物”。

2.2 科学意义

本项目的意义不在于用计算完全取代湿实验, 而在于把不可穷举的条件空间变成可排序的候选集合: 先预测可能具有强响应、异常响应或高不确定性的条件, 再把实验资源集中到最值得验证的部分。若模型能够在新菌株和新药物上保持可靠性, 可用于提出机制假设、发现菌株特异耐受与敏感性, 并为后续主动学习提供实验选择依据 [3, 4]。

同时, 本赛题也是一个评价方法学的机会: 与只追求单一总相关系数相比, 分解基础谱、共享响应与条件特异残差, 并对每条 OOD 分支设置可否证门槛, 更接近“模型是否真正学到生物响应”的科学问题。

3 技术方案与方法路线

本节方法均已映射到仓库内的相对代码位置, 核心实现、运行入口与复现级别见表 23; 公开仓库以项目根目录为路径起点。

3.1 技术方案

3.1.1 数据合同与预处理

数据统计得到表 2 所示规模。名义实验设计空间不能直接当作独立样本数，因为真实数据还包含对照、质控、重复及未完整覆盖的组合。

表 2: 数据规模与任务含义

数据范围	样本数	含义
Train	5,920	可用于拟合的数据，含处理、DMSO/Water 对照和 QC。
val_strain_only	1,547	新菌株、已见化合物。
val_chem_only	1,065	已见菌株、新化合物。
val_both	269	菌株与化合物同时未知。
val_time	157	时间条件留出。
Validation 合计	3,038	仅用于规定的评估，不参与 fold 内特征选择。

预处理遵守以下边界：

- 1. 只对有效正值质谱强度取 $\log_2$ ；原始缺失继续保留为缺失，不能先填 0 再取对数。
- 2. 每个交叉验证折的缺失率、均值、标准差、类别词表和低秩基都只用该折的拟合子集计算。
- 3. source、instrument 和 plate 属于测量环境；它们与菌株、药物、培养基、温度和时间分开建模。
- 4. 完整输出合同始终是 5,243 个蛋白坐标，缺失筛选只决定主要模型拟合哪些坐标，不改变提交宽度。

蛋白 p 在 fit 数据中的缺失率为

$$r_p^{\text{miss}} = 1 - \frac{1}{N_{\text{fit}}} \sum_{i \in \text{fit}} M_{i,p}. \tag{6}$$

当前主要口径为

$$\mathcal{P}_{0.8} = \{p : r_p^{\text{miss}} \leq 0.8\} = \{p : r_p^{\text{obs}} \geq 0.2\}. \tag{7}$$

因此，缺失率**恰好为 80% 的蛋白仍保留**；只有严格大于 80% 才由训练集均值基线补全。使用全部训练集统计时，4,422 个坐标进入主要拟合，821 个坐标采用仅由训练集估计的补全基线，其中 189 个在训练集中完全没有有效观测：

$$5,243 = 4,422 + 821. \tag{8}$$

这 4,422 个坐标覆盖 validation 中 98.72% 的**有效观测单元**，并非“保留了 98.72% 的蛋白”。阈值敏感性表中的 98.733% 是 train 有效观测单元覆盖，两个数字的数据范围不同。80% 是工程参考而非生物学阈值。采用直接实测对照和共同重复掩码的两套分组实验表明，90% 阈值虽有一致的

小幅改善，但 Raw-FC 与条件个性的最大增益仅约 $+0.00200/+0.00206$ ，低于预设的 $+0.003$ 替换门槛；50% 与 70% 均退步，因此保留 80%，详见表 18。

3.1.2 评价指标：同时衡量终点、响应和个性

本文依据赛题材料，将评价目标归纳为表 3 所示六类模块，并据此建立统一的模型比较协议。

表 3: 六类评价模块及其建模含义

模块	权重	本项目中的理解
匹配对照原始 FC	25%	处理样本相对 DMSO/Water 对照的变化模式。
绝对保真度	20%	完整蛋白谱的逐样本、逐蛋白相关和误差。
上下文均值残差	20%	去除相同背景共享响应后，是否恢复新药个性。
药物均值残差	20%	去除同药共享响应后，是否恢复新菌株调制。
双重未知/时间外推	10%	最难 OOD 条件下的完整性与轨迹泛化。
高响应蛋白与 DEP	5%	强变化蛋白的方向、Recall@K、F1/AUPRC 等。

对样本 i ，Endpoint PCC 为跨蛋白相关：

$$\rho_i^{\text{end}} = \text{corr}_p(\hat{y}_{i,p}, y_{i,p}), \quad (9)$$

它衡量完整谱形状，但容易被稳定基础丰度主导。若 $\mathbf{y}_i^{\text{ctrl}}$ 是匹配对照，则

$$\Delta_i^{\text{true}} = \mathbf{y}_i^{\text{treat}} - \mathbf{y}_i^{\text{ctrl}}, \quad (10)$$

$$\Delta_i^{\text{pred}} = \hat{\mathbf{y}}_i^{\text{treat}} - \mathbf{y}_i^{\text{ctrl}}, \quad (11)$$

Raw-FC PCC 为两者跨蛋白相关。它是相关系数，不是“多少蛋白预测正确”的准确率。当前数据缺少正式 chemical→DMSO/Water 映射，因此 pooled-control Raw-FC 只能作为探索性诊断。

为了检验条件个性，按相同背景构造共享响应 μ_{ctx} ，或按相同药物构造共享药物响应 μ_d ，再比较残差：

$$\mathbf{r}_i^{\text{ctx}} = \Delta_i - \mu_{\text{ctx}(i)}, \quad (12)$$

$$\mathbf{r}_i^{\text{drug}} = \Delta_i - \mu_{d_i}. \quad (13)$$

条件个性进一步去除全部条件共享的逐蛋白平均响应：

$$\mathbf{r}_i^{\text{ind}} = \Delta_i - \frac{1}{N} \sum_{j=1}^N \Delta_j, \quad (14)$$

其 PCC 比较预测与真实的 $\mathbf{r}_i^{\text{ind}}$ 。它与 context residual 和 drug residual 分别回答“相对全部条件”“相对同背景药物”“相对同药条件”的偏离是否正确，三者不能互换。本项目还同时报告 RMSE 和条件方差比。条件方差比定义为

$$\text{VR} = \frac{\sum_{i,p} (\hat{y}_{i,p} - \bar{\hat{y}}_p)^2}{\sum_{i,p} (y_{i,p} - \bar{y}_p)^2}. \quad (15)$$

VR = 0 表示所有条件收到同一预测；接近 1 才表示总体变化幅度相近，但仍需 PCC 和 RMSE 判断方向与数值是否正确。VR 也可以按药物、菌株和药物 × 菌株交互分别计算。

若要识别“哪些药物具有特殊影响”，可在训练集内计算药物响应签名

$$\bar{\Delta}_d = \frac{1}{|\mathcal{I}_d|} \sum_{i \in \mathcal{I}_d} \Delta_i, \quad (16)$$

并从中去除相同实验背景的共享响应：

$$\mathbf{q}_d = \bar{\Delta}_d - \mu_{\text{matched ctx}}. \quad (17)$$

只有当 $\mathbf{q}_d$ 在重复间可复现、强于身份置换/符号反转负对照，并在 held-out 条件中仍能预测，才能称为药物特异信号。相关结果以聚合指标报告。

与评价目标一致的候选训练损失。 核心模型以终点误差为主要训练目标，并将 FC 与残差指标作为独立评价指标。本研究进一步完成了仅使用训练集、按实体分组的折外预测（OOF）多目标损失实验 [30]：

$$\mathcal{L} = \lambda_{\text{end}} \mathcal{L}_{\text{end}} + \lambda_{\text{FC}} \mathcal{L}_{\text{FC}} + \lambda_{\text{ctx}} \mathcal{L}_{\text{ctx}} + \lambda_{\text{drug}} \mathcal{L}_{\text{drug}} + \lambda_{\text{amp}} \mathcal{L}_{\text{amp}}. \quad (18)$$

前四项分别约束完整蛋白谱、相对对照的扰动、同背景下的药物个性和同药物下的菌株调制；幅度项用于避免模型只预测正确方向却系统性压缩变化。该实验在两类 OOD 的 Raw-FC 与高响应蛋白指标上产生了小而稳定的改善，但两个场景均未通过完整晋级门槛，因此没有替换核心模型。与对照有关的项只在每个训练折内按有效 vehicle 规则构造；化合物与 DMSO/Water 的正式映射发布前，Raw-FC 结果按探索口径解释。完整结果见第 4.2.5 节。

高响应蛋白专项指标。 PCC 衡量整个向量的共同变化，但未必能判断模型是否找对最强响应蛋白。本研究实现 signed Recall@K、Precision@K、AUPRC、top-K 方向一致率，以及高响应蛋白上的 MAE/RMSE。高响应阈值与 K 均在每个 outer-fit 内独立确定；若官方给出 DEP 定义，则统一采用官方规则。

3.1.3 从 baseline 到 OOD 路由模型

第一条 sanity baseline 对每个蛋白输出训练均值：

$$\hat{y}_{i,p} = \mu_p^{\text{train}}. \quad (19)$$

该模型不读取任何条件，其条件方差必然为零。它不是预期的最终模型，而是衡量“仅复制基础蛋白谱就能得到多高分”的标尺。

全局核心模型使用 metadata Ridge。类别字段在每个拟合子集内建立 one-hot 词表；未见类别对应的特征块全为零。温度使用拟合子集的均值和标准差进行标准化，时间先取 $\log(1+t)$ ，再使用同一拟合子集的统计量标准化。令 $\mathbf{z}_i$ 为这些特征，则每个蛋白执行带缺失掩码的 Ridge：

$$\hat{\mathbf{y}}_i^{\text{core}} = \mathbf{z}_i^{\text{T}} \mathbf{B}, \quad \hat{\mathbf{B}} = \arg \min_{\mathbf{B}} \mathcal{L}_{\text{end}} + \lambda \|\mathbf{B}\|_2^2. \quad (20)$$

核心模型使用 biological metadata、source 和 instrument；plate 仅用于消融，不进入正式核心模型。

为防止把测量系统误当作生物机制，核心可更明确地拆成：

$$\hat{y}_i = f_{\text{bio}}(s_i, d_i, m_i, T_i, t_i) + \mathbf{b}_{\text{source}(i)} + \mathbf{b}_{\text{instrument}(i)}. \quad (21)$$

f_{bio} 预测生物响应，后两项只做观测校准。整板留出消融表明 source+instrument 的收益可跨新 plate 保留；plate 的收益则反转，因此不加入预测项。QC 特征仅依据数据中的实际字段构造，并通过未见 plate 验证。

高维响应用低秩 decoder 表示：

$$\hat{\Delta}_i = D\mathbf{h}_i, \quad D \in \mathbb{R}^{5243 \times r}, \quad r \ll 5243. \quad (22)$$

带外围知识的 token 模型。 公平架构实验表明，只把同一组身份 one-hot 换成 MLP 未能改善整种药物未知：被完整留出的药物都会落到相同 unknown 表示。因此，Transformer 候选不只读取 metadata，而是把公开化学结构、蛋白功能/网络知识和可用的菌株公共特征编码为独立 token。设 $\mathbf{x}_i^{\text{ctx}}$ 为实验条件， $\mathbf{x}_i^{\text{drug}}$ 为 ChEBI 结构的 Morgan 指纹与基础描述符 [25]， $\mathbf{x}_i^{\text{strain}}$ 为许可与映射均通过的菌株特征， $\mathbf{x}_k^{\text{prot}}$ 为由 SGD/GO、SGD 注释中的 Reactome 引用和 STRING 网络聚合的蛋白知识视图 [23, 24, 27]，则输入序列为

$$\mathbf{X}_i = [\mathbf{x}_i^{\text{ctx}}, \mathbf{x}_i^{\text{drug}}, \mathbf{x}_i^{\text{strain}}, \mathbf{x}_1^{\text{prot}}, \dots, \mathbf{x}_K^{\text{prot}}]. \quad (23)$$

不同 token 先投影到相同维度，加入类型、位置和显式缺失嵌入，再由小型自注意力编码器产生 rank-32 响应系数，经每折独立拟合的解码器还原蛋白终点。注意力结构只提供跨模态交互能力，并不自动等同于生物机制；是否保留该分支，取决于外围知识相对身份置乱、同容量 MLP、仅使用实验条件的 Transformer 和强 Ridge 是否产生稳定净增益 [29]。

公共资产在不读取比赛响应的条件下预先构建并冻结版本。当前版本记录 ChEBI release 253 (2026-07-07)、GO Basic 2026-06-19、SGD GAF 2026-06-17 和 STRING v12.0。严格连接口径为：ChEBI 结构覆盖 train 中 22/37 个药物身份；蛋白 token 的别名唯一映射覆盖完整表头 5,094/5,243，在预先固定的 384 蛋白评估面板中覆盖 373/384，但这不表示每个已映射蛋白都同时具有完整 GO、Reactome 与 STRING 信息；Peter 等菌株资源可映射 train 的 3/4 个菌株，当前实验未启用该视图 [26, 23, 24, 27, 22, 21]。未匹配实体统一使用“全零公开特征 +missing flag”。

该实验的主判定采用**全实体主分析**：把 22 个有严格结构映射和 15 个无映射、使用缺失标记的非对照训练药物全部纳入评价。结构已覆盖子集只能定位候选信号，不能代替主结论。候选模型、仅使用实验条件的 Transformer 和同容量知识 MLP 使用相同的生物条件特征、低秩解码器、初始化与训练轮数；主 Ridge 直接拟合标准化蛋白终点，不受低秩瓶颈限制。只有候选同时胜过最强主对照，并且在结构打乱、实体错配和去除蛋白知识后出现符合预期的下降，才允许另立协议扩展到完整 5,243 蛋白。

公共功能表征聚类的多头输出。 为了检验“相关蛋白共享一个输出分支”是否比单一输出头更合适，本研究另设功能分组 multi-head。对每个公共酵母蛋白，只读取冻结的 GO（前 128 维）、Reactome 引用（64 维）和 STRING 邻域（128 维）固定维度哈希表征（signed hash）；先逐块归

一化，再用不读取比赛响应的确定性聚类将 7,504 个公共蛋白分为 8 个匿名功能组。无法注释或无法与比赛表头唯一连接的蛋白分别进入未注释组和映射缺失组。由于现有 signed-hash 特征不可逆，这些组不能命名为“代谢”“翻译”或“应激”等具体通路。

令 $g(p)$ 为蛋白 p 的公共分组，条件共享编码为 $\mathbf{h}_i = f_\theta(\mathbf{x}_i)$ ，则每个组使用独立的轻量适配器和输出头：

$$\hat{\mathbf{y}}_{i,G_k} = \mathbf{W}_k \text{GELU}(\mathbf{A}_k \mathbf{h}_i) + \mathbf{b}_k, \quad G_k = \{p : g(p) = k\}. \quad (24)$$

主比较包括同容量 single-head、正确公共分组 multi-head 和保持每组大小不变但让所有已映射蛋白换组的 assignment-deranged multi-head。只有正确分组在 whole-chemical 与 whole- K_{bio} 中同时胜过两类对照，且条件个性不下降，才能说明公共功能结构带来额外价值；否则只能判断多头架构未获得功能分组带来的增量收益。

三种可追溯知识分支。 匿名功能组实验之后，知识增强按“命名输出模块、药物输入机制、菌株输入差异”分为三个可独立消融的分支。第一，使用 GO Basic 与 SGD GAF 构建命名、多标签的酵母 GO-slim biological-process 归属，比较正确通路共享、保持通路大小和蛋白度数分布的归属置换，以及同容量单头。第二，将来源、许可和唯一映射均已登记的药物靶点作为输入 token，并沿高置信 STRING 边构建零跳或一跳局部蛋白网络；缺失靶点以显式 missing token 表示，并设置靶点身份置换、度匹配节点错配和蛋白坐标错配。第三，将菌株相对参考基因组的基因存在/缺失、拷贝数、移码和功能缺失负荷聚合为基因与通路特征；无法权威映射的菌株进入 missing 分支，并与菌株身份置换和等维随机特征比较。三条分支均使用相同的 384 蛋白面板、whole-chemical 与 whole- K_{bio} 分组、直接实测对照共同掩码和强 Ridge 基线，只有在主指标、误差、折稳定性和相应身份负对照上同时通过才允许扩展至全面板 [23, 22, 28, 27, 21]。

药物输入机制实验采用 ChEBI 到 PubChem 再到 STITCH 的唯一映射，以 STITCH 综合置信分数 ≥ 400 提取直接靶点，并沿 STRING v12.0 综合置信分数 ≥ 700 的边传播一步。直接靶点、一步邻域、带符号靶点及其一步邻域经冻结投影形成 136 维特征，再与生物条件特征拼接，由每折独立拟合的 rank-32 蛋白响应解码器输出。严格映射覆盖训练集中的 14/37 个药物，STRING 覆盖固定面板中的 360/384 个蛋白；其余药物使用缺失标记并回退到同折直接 Ridge。主分析纳入全部有映射与无映射药物，覆盖子集仅作诊断。由于 STITCH v5.0 派生资产采用 CC BY-NC-SA 4.0，本分支当前仅作为研究性验证，不作为可直接部署的提交依赖 [28, 27]。

菌株输入差异实验读取 Peter 等 (2018) 公开资源中的非移码功能缺失 (LoF)、移码、基因存在/缺失、拷贝数降低和拷贝数升高五类事件 [21]。对每个菌株，将基因事件按 64 个命名 SGD 生物过程通路聚合为归一化负担，再仅使用 1,010 个公共菌株进行 PCA，得到固定 8 维特征。权威的大小写敏感精确映射覆盖训练集中的 3/4 个菌株和已发布六株中的 5/6；未映射菌株回退到同折 metadata Ridge。评价包括四折整株留出、五折未见 K_{bio} 组合、全实体主分析与已覆盖子集诊断，并设置同维随机特征、基因-通路错配及全部五种非同一菌株身份分配。

LoF/移码探索信号另以响应无关的确定性规则冻结第二个 384 蛋白独立确认面板，与探索面板零重叠；模型、阈值和负对照均在读取该面板数值前冻结。Peter 公共资源尚缺少可机器核验的再分发许可文本，因此当前编码器仅用于研究验证并等待源站条款确认，原始公共矩阵不进入提交包。

对进一步的嵌套收缩方案，先执行**保守停止式 (fail-closed)** 可识别性审计，而不直接拟合数

值模型。第三个 384 蛋白独立面板仅依据表头、以响应无关的确定性规则锁定，并与前两个面板保持零重叠；随后只用身份信息检查每个内层拟合子集是否具有足够多的独立公共菌株样本，以及公共菌株特征是否在已有菌株 one-hot 之外增加设计矩阵秩。若不可识别，则在读取任何官方蛋白响应数值前停止。

最终模型不是让一个网络同时承担所有 OOD，而是使用冻结路由：

$$\hat{y}_i = \hat{y}_i^{\text{core}} + g_s(i)\mathbf{R}_i^{\text{strain}} + g_t(i)\mathbf{R}_i^{\text{time}} + g_d(i)\mathbf{R}_i^{\text{chem}}, \quad (25)$$

其中门控 $g_s, g_t, g_d \in \{0, 1\}$ 只在对应专家通过预先固定的 OOD、RMSE、折稳定性和负对照阈值时开启。双重未知没有通过的专家，因此回退 core。当前 g_d 只对应共享校准，不代表模型已经恢复未见药物的机制或条件个性。




图 2: 当前分场景候选与受限路由框架。

若推理输入额外提供同条件实测对照，则在上述无对照路由之后可启用独立的成对仿射校准；它要求处理与对照在相同有效重复样本对上聚合。该分支不属于默认实验条件输入合同，对聚合估计目标敏感；缺少同条件实测对照或溶剂匹配规则不明时必须关闭。

3.2 扩展研究路线

低秩表示、公平 MLP/残差架构、动态/前缀、多目标、不确定性、外围知识 Transformer、公共功能表征聚类多头输出、命名 GO-slim 输出分支、药物靶点局部网络、菌株基因组/CNV，以及不使用 RAG 的开放权重模型均已有实验结果；RNA 编码器直接迁移、Neural/Latent ODE、可追溯 RAG、LoRA 与前瞻主动实验作为扩展候选。所有候选均需通过相同 OOD 评价体系后才能进入最终模型。

3.2.1 从 RNA 扰动预测迁移的方法

单细胞 RNA 扰动研究提供了可迁移的网络结构和表示学习方法。scGen 使用 VAE 和潜空间向量运算预测未见细胞背景的反应 [6]；CPA 将基础状态、扰动、剂量和协变量解耦并组合 [7]；chemCPA 进一步使用化合物表示面向未见药物建模 [14]；GEARS 通过知识图谱和 GNN 预测未见遗传扰动组合 [8]。由于 RNA 与蛋白质组的输入坐标、缺失机制和输出含义不同，本研究不预

设这些权重能够即插即用，而是把开源 RNA 模型的 encoder embedding 作为需要实验检验的跨模态表示。对应到本赛题，可形成表 4 的候选。

表 4: RNA 扰动方法可迁移的结构及边界

方法家族	可迁移思想	需要重新验证的部分
scGen 类潜空间运算	加载开源实现；比较从头训练、冻结 RNA encoder 和 fold 内微调三种方式。	RNA embedding 需经同源基因/GO 对齐和模态适配器映射到蛋白空间。
CPA 与 chemCPA 类条件自编码	分解基础状态、化合物表示、时间和环境协变量，并提取条件 embedding。	新药泛化依赖可靠 SMILES/靶点、许可和足够多化合物。
GEARS 类图模型	以 SGD/GO/STRING 作为蛋白或基因关系先验。	网络边无方向或不完备，必须防止过度平滑。
Systema 类评价	去除共享变化，专门测条件特异响应。	参考从转录 centroids 改为蛋白对照和条件残差。

具体实验分为三组：(1) 只复用 scGen、CPA/chemCPA 或 GEARS 的网络结构，在比赛训练折内从头训练；(2) 冻结可获得的 RNA encoder，经同源基因或 GO 通路对齐后提取 embedding，再训练轻量适配器和蛋白 decoder；(3) 只在每个外层 OOD 的训练部分微调 encoder 与适配器。三组实验均与 PCA/SVD 低秩表示和从头训练网络比较，并分别进行 whole-drug、whole-strain 与双重未知验证。只有在相同输出、mask、对照和 OOD 协议下稳定提高条件响应指标的迁移方式才进入最终模型。

3.2.2 受条件控制的低维蛋白动态模拟器

本赛题的多个时间点可以进一步抽象为一条群体平均蛋白响应轨迹，而不是彼此无关的终点预测。对同一菌株、化合物、培养基和温度组成的基础条件 c_i ，先在训练折内构造对照中心化响应并压缩到 r 维潜状态：

$$\Delta \mathbf{y}_i(t) = \mathbf{y}_i^{\text{treated}}(t) - \mathbf{y}_i^{\text{control}}(t), \quad \mathbf{z}_i(t) = E(\Delta \mathbf{y}_i(t)), \quad \mathbf{z}_i(t) \in \mathbb{R}^r, \quad r \ll 5243. \quad (26)$$

编码器 E 、蛋白掩码、中心值和解码器均由当前训练折估计。离散时间候选采用 LSTM 或 GRU 状态转移 [15]：

$$\mathbf{z}_i(t_{k+1}) = \text{GRU}_{\theta}(\mathbf{z}_i(t_k), \mathbf{e}_{d_i}, \mathbf{e}_{s_i}, m_i, T_i, \Delta t_k), \quad (27)$$

连续时间候选则使用 Neural ODE 或 Latent ODE[16, 17]：

$$\frac{d\mathbf{z}_i(t)}{dt} = f_{\theta}(\mathbf{z}_i(t), \mathbf{e}_{d_i}, \mathbf{e}_{s_i}, m_i, T_i), \quad \hat{\mathbf{y}}_i(t) = \hat{\mathbf{y}}_i^{\text{control}}(t) + D\mathbf{z}_i(t). \quad (28)$$

这里的“模拟器”是比赛蛋白质组空间中的数据驱动代理模型，不是完整模拟 DNA 复制、转录、代谢、细胞形态或单细胞生命史。当前数据若只包含从基线施加一次扰动后的群体测量，就只能验证固定扰动下的平均轨迹，不能据此声称可以模拟“先加药 A、再换培养基、随后加药 B”的任意操作历史。

实验分成两个不可混写的任务。零状态生成任务要求模型从对照或零潜状态开始预测完整轨迹，验证时不读取任何真实处理后状态。Rolling-origin 任务则允许在预先固定的截止时间 c 读取一次真实当前状态：

$$\mathbf{z}_c = E(\mathbf{y}(c) - \hat{\mathbf{y}}^{\text{core}}(c)), \quad \hat{\mathbf{z}}(t) = g_\theta(\mathbf{z}_c, \mathbf{x}, t, c, t - c), \quad t > c. \quad (29)$$

随后不得再次注入真实状态。 g_θ 可以是直接预测目标时间状态的静态网络，也可以是线性状态转移、LSTM/GRU 或 Latent ODE。验证必须完整留出菌株 $\times$ 药物 $\times$ 培养基 $\times$ 温度条件，并比较 prefix persistence、当前 rank-32 模型、同参数量静态网络、时间置乱和前缀身份错配。只有递归候选稳定超过同信息、同容量的静态网络，才能把增益归因于额外动态规律；否则最多说明“当前状态有助于预测未来”。

3.2.3 条件化预测分布与不确定性旁路

生成式建模需要同时给出预测和可信的不确定性。当前数据聚合后，每个 condition-time 基本只有一个蛋白响应向量，尚不足以识别真正的多峰分布；直接训练完整 cVAE 难以区分真实多模态、posterior collapse 与任意噪声编码。因此先使用条件异方差潜空间高斯：

$$\mathbf{z} | \mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_\theta(\mathbf{x}), \text{diag } \sigma_\theta^2(\mathbf{x})), \quad \mathbf{y} \approx \boldsymbol{\mu}_y + \mathbf{D}\mathbf{z}, \quad (30)$$

其中推理只读取条件 $\mathbf{x}$ ，留出样本的蛋白目标不进入编码器。确定性与异方差模型使用完全相同的参数量；预测方差同时与仅由拟合子集估计的常数方差、留出行置乱及关闭随机采样三类对照比较。未见 K_{bio} 组合时，方差能够稳定识别更困难条件，但 NLL 训练损害了点预测，故当前只保留为主动实验与置信度旁路，不接入提交均值。若未来获得同条件多重复或真正的分布标签，再重新评估 cVAE、flow 或 diffusion。

3.2.4 开放知识与实体 encoder

新实体泛化最终需要不依赖 one-hot 身份的描述符：

$$\mathbf{e}_s = \text{Enc}_s(\text{SNP}, \text{Indel}, \text{CNV}, \text{aneuploidy}), \quad (31)$$

$$\mathbf{e}_d = \text{Enc}_d(\text{SMILES}, \text{fingerprint}, \text{target}, \text{MoA}), \quad (32)$$

$$\hat{\Delta}_{i,p} = D_\theta(\mathbf{e}_s, \mathbf{e}_d, m_i, T_i, \phi(t_i), \mathbf{u}_p), \quad (33)$$

其中 $\mathbf{u}_p$ 可来自 SGD、GO、YeastPathways、STRING 或蛋白序列。接入顺序为：蛋白 ID 对齐与 pathway 聚合、菌株基因组 encoder、轻量图正则及 Yeast8 代谢约束。每个模块均单独检验其对不同 OOD 场景的增益。

开放数据采用两阶段门控：

1. **公共任务门槛**：模型在公共任务自身的 whole-entity split 上显著胜过简单 baseline 和身份或坐标负对照；
2. **比赛迁移门槛**：冻结公共模型，在仅使用比赛训练集的整种药物留出或整株留出折外预测中证明额外增益。

除排行榜指标外，开放知识路线还增加一个**外部机制一致性验证**：选择具有公开酵母蛋白质组或通路证据的少量药物，冻结比赛模型后预测其高响应蛋白与通路分数，再与公开实验中的变化方向、通路富集及已知靶点邻域比较，并加入无关药物、随机通路和身份错配负对照。该验证不能替代官方盲测；只有公共任务自身通过预设门槛，且冻结后在 competition-train whole-entity OOF 中继续增益，相关特征才可接入正式模型。当前公共数据只证明局部桥接信号，尚未改善最终新药 zero-shot 路由。

3.2.5 RAG、候选机制链与可选 LoRA

该模块检验语言模型能否把公开生物知识转换成对未知条件预测有用的**数值特征**。前置诊断使用 Qwen3 8B 与 Gemma 12B 的预训练知识，将药物与菌株名称转成 49 维机制轴；在严格 whole-drug OOF 中，双模型共识使 Raw-FC 降低 0.01414、Endpoint RMSE 增加 0.12595，说明无检索证据的名称知识不足以替代可核查的结构与机制表征。

扩展方案首先建立版本冻结的公开知识库，内容包括公共酵母蛋白质组、化合物结构与已知靶点、菌株变异与 CNV，以及 SGD、GO、YeastPathways、STRING 和公开文献。RAG 检索与当前药物、菌株、培养基、温度和时间有关的条目，再将相同证据交给两个开放权重语言模型独立分析。所有资料均保留数据库名称、条目编号或文献编号。

对于第 i 个条件，模型输出固定格式的候选机制链：

$$\begin{aligned} (d_i, s_i, m_i, T_i, t_i) &\longrightarrow \text{候选靶点或过程} \\ &\longrightarrow \text{通路或蛋白模块} \\ &\longrightarrow \text{预期变化方向及依据.} \end{aligned} \quad (34)$$

菌株变异、培养基、温度和时间作为链中的修饰条件。除候选靶点、通路和蛋白模块外，每个 LLM 还输出相关菌株变异或调制因素及其重要程度、证据覆盖率、置信度和弃权标记；两个模型提出的共同路径和分歧分别保留为结构化字段。

候选机制链随后被转换成固定长度的特征向量：

$$\mathbf{h}_i = [\text{候选靶点与通路分数, 受影响蛋白模块,} \quad (35)$$

$$\text{菌株调制特征, 证据覆盖率, 双模型共同项与分歧, 置信度, 弃权标记].$$

比赛的监督标签是蛋白丰度，不是基因表达。基因层知识须用固定对齐表，将基因或 ORF 映射到比赛蛋白坐标或通路模块。mRNA 表达、蛋白丰度、蛋白活性、磷酸化和代谢通量不是同一个量。

在训练集中，先用处理样本相对于匹配溶剂对照的蛋白变化构造监督信号，并可进一步聚合为通路响应：

$$z_{i,k} = \frac{1}{|P_k|} \sum_{p \in P_k} \Delta y_{i,p}, \quad (36)$$

其中 P_k 是第 k 个通路或蛋白模块。LLM 负责生成候选机制、菌株调制特征和置信信息 $\mathbf{h}_i$ ；最终变化方向和数值幅度由训练折内的监督模型结合化合物、菌株和实验条件特征学习：

$$\hat{\mathbf{z}}_i = f_{\theta}(\mathbf{h}_i, \mathbf{e}_{d_i}, \mathbf{e}_{s_i}, m_i, T_i, t_i), \quad \hat{\mathbf{y}}_i = \hat{\mathbf{y}}_i^{\text{core}} + D\hat{\mathbf{z}}_i. \quad (37)$$

其中 $\mathbf{e}_{d_i}$ 和 $\mathbf{e}_{s_i}$ 分别是化合物与菌株描述符， D 是蛋白响应 decoder。若两个 LLM 均低置信或弃权，则该条件不启用 LLM 修正，直接回退稳定核心模型。若进一步让本地 LLM 观察训练数据，

也只向它提供当前训练折内聚合后的通路响应示例，用于归纳“机制特征 $\rightarrow$ 响应”的候选规则；被完整留出的药物及其响应不得出现在检索、提示、示例选择或参数调整中。

检验采用仅使用训练集的整种药物留出折外预测：每次完整留出一种药物的全部菌株、时间和培养条件，只用其他药物构建特征、拟合 f_θ 与 D 并选择超参数，再预测该未见药物。除 Raw-FC、药物残差、条件个性和 RMSE 外，还要比较关闭 RAG、药物与机制链身份错配、响应方向置乱、通路坐标置乱、单模型和同容量随机特征等负对照。只有真实机制特征在多个留出药物上稳定优于核心模型和负对照，才能说明 LLM 提供了可迁移信息；否则该路线记录为未通过。

LoRA 与 RAG 推理分开评估。由于不使用 RAG 的双模型未通过整种药物留出门槛，且训练侧只有 37 个非对照药物、没有机制文本真值，LoRA 放在可追溯 RAG 或公共机制监督获得稳定增益之后。若使用比赛训练响应，LoRA 在每个外层 OOD 的训练部分内独立训练，并与仅使用 RAG、随机特征和不微调模型进行公平比较。

主动实验属于与候选机制链互补的扩展方向，其闭环为：

$$\text{已有数据} \rightarrow \text{模型与不确定性} \rightarrow \text{选择实验} \rightarrow \text{真实测量} \rightarrow \text{更新模型}. \quad (38)$$

闭环中的新标签必须来自新增实验测量。候选实验可按下式排序：

$$a(x) = U(x) + \beta D(x, \mathcal{D}) + \gamma S(x), \quad (39)$$

其中 $U(x)$ 可由 GP 后验方差、深度集成分歧或交叉验证预测离散度估计， $D(x, \mathcal{D})$ 衡量与已测条件的差异， $S(x)$ 表示预先定义的科学价值。高不确定性表示“值得测量”，不等于“模型一定错误”。若规则允许为一个新药先测少量精确生物条件，可进一步比较 GP、核回归或贝叶斯更新等 few-shot 校准方法；这属于主动校准，不是 zero-shot，最终仍需真正盲测或前瞻实验确认。

3.3 数据来源、依赖工具与运行流程

项目将数据分为三层：比赛授权 train、只用于规定评估的 validation，以及公共知识/公开组学。三层数据使用独立目录、哈希和运行清单管理。核心流程为：

1. 校验文件校验值、字段定义、数据角色和输出宽度；
2. 按 OOD 实体或完整条件身份生成分组交叉验证折；
3. 在每个 fold 内拟合缺失 mask、标准化、类别词表和低秩基；
4. 训练 core 与单一候选专家，同时运行容量匹配的负对照；
5. 只保存聚合指标、门控结果、代码版本和依赖版本；
6. 候选仅在训练集内部通过预设门槛后，才允许一次性进入固定验证；未通过则回退到核心模型。

4 实验结果与可行性验证

4.1 基线与数据特性

当前实验回答了三个递进问题：

1. 一个完全忽略条件的平均蛋白谱，能在总体指标上得到多高分？
2. 只使用封闭 metadata，能否建立稳定、无明显泄漏的全局核心模型？
3. 在不同 OOD 场景中，是否存在能够稳定增加条件个性的专门分支？

本报告仅呈现经过独立复算的聚合结果。不同评价协议的绝对分数不能直接排名；只有使用相同数据划分、基线、缺失掩码和对照定义时，模型增益才具有可比性。

本节各实验对应的统一入口、历史源码和冻结证据位置见表 24。其中“聚合证据回放”表示核对源文件哈希和冻结标量，并不等同于在新框架中重新训练历史模型。

4.1.1 平均值 baseline：高总体相关不等于条件响应

每个样本均预测为相应蛋白在训练集中的平均值，得到表 5。该模型没有读取药物、菌株、培养基、温度或时间。

表 5：每蛋白训练均值 baseline 的固定 validation 结果

范围	Flattened PCC	Pooled R^2	逐蛋白平均 R^2	条件方差比
全部 validation	0.9411	0.8856	-0.0413	0
双重未知	0.934	0.873	-0.268	0

进一步比较训练集和固定验证集中每个蛋白的平均丰度，得到 PCC 0.9973，不再拟合的直接迁移 $R^2 = 0.9946$ 。这说明基础蛋白丰度轮廓在两个集合间极其稳定，从而解释平均值模型为什么能获得 0.94 的总体相关。与此同时，逐蛋白 R^2 为负且条件方差比为零，说明它没有恢复“同一蛋白在不同条件间如何变化”。

因此，“平均值陷阱”的准确含义是：如果复杂模型只在总体 Endpoint 上表现很好，却没有显著提高条件响应指标，它可能仍只是在复制稳定基础谱。平均值 baseline 本身没有条件个性是正常的；陷阱来自错误的评价方式，而不是 baseline 做错了。

4.1.2 Metadata Ridge 与批次消融

推荐的全局核心为 biological metadata + source + instrument。固定四类 validation 的 Endpoint macro PCC 为 0.985145。探索性 pooled-control Raw-FC PCC 为 0.326278；这表示变化模式存在中等相关，不是 32.6% 的“准确率”，并且由于 chemical→vehicle 映射尚未正式提供，该数值只作为诊断。

批次消融给出了是否纳入观测字段的证据：

表 6: 批次字段的可迁移性消融 (Raw-FC 相对 biological core 的增益)

候选字段	固定 validation	整板未见测试	结论
source + instrument	+0.10537	+0.11865	跨未见 plate 仍保留收益, 纳入 core。
plate	+0.08895	-0.01535	收益在整板留出时反转, 判为记忆捷径并排除。

该实验只能证明 source + instrument 的收益能跨新 plate 保留, 不能外推成“跨全新 source 或 instrument 也一定有效”。

4.2 模型比较与泛化结果

4.2.1 已通过或有限通过的 OOD 分支

表 7: 当前 OOD 分支的同协议增益与适用边界

场景	模型与协议	主要增益	判定与边界
新菌株、药已见	跨菌株残差记忆; 严格 4 折整株留出折外预测	Raw-FC +0.030936 (4/4); drug residual +0.018734; individuality +0.026257	已通过。限定场景路由的 Raw-FC 为 +0.033186、药物均值残差为 +0.044781; 不适用于全新药物。
新时间、base 已见	响应记忆 + rank-32 解码器 + 对数时间; 严格 6 折整时点留出折外预测	Raw-FC +0.044988; individuality +0.052365; time residual +0.028669, 均 6/6 为正	已通过。相对时间置乱对照仍有额外证据; 仅处理已见基础条件的新时间。
新化合物、菌株已见	新药共享校准; 固定验证	Raw-FC +0.041393; context residual 仅 +0.000169	有限通过。只能称共享校准, 未证明新药机制或个性。
双重未知	保守候选相对 core	Raw-FC +0.002523	未通过, 低于预注册 +0.005 门槛, 最终回退 core。

时间模型还提供了一个重要的反记忆证据: 在同一基础条件的新时间上, 增益为 +0.029818, 高于完整条件键相同场景的 +0.009791; 这支持它学习了时间轨迹, 而不仅是记忆完整条件组合。但它仍不是完整细胞动力学模型。

4.2.2 低维动态模型小规模验证：递归状态未带来额外收益

为检验“将低维蛋白响应视为可演化细胞状态”是否对本数据有用，研究在首次读取标签前以响应无关的确定性规则固定了 384 个蛋白，并在六个严格整时点留出外层折中比较线性状态转移、小型 GRU、同阶容量静态 MLP 与当前 rank-32 时间轨迹模型。每折的蛋白掩码、metadata 核心、PCA/解码器、潜状态标准化和模型参数均只由该折拟合子集估计。验证时从零潜状态开始自由滚动，不读取真实前一时刻蛋白状态。

数据统计显示，train 中有 592 条完整六时点处理轨迹和 4,242 个相邻状态转移，数量足以开展小型动态实验。但这是破坏性质谱得到的群体平均轨迹，不是同一细胞的连续录像；且 plate 与时间完全绑定，因此实验加入整板时间置乱、完整生物条件轨迹错配和无递归状态的静态网络对照。

表 8: 低维动态模型 384 蛋白 whole-time 验证（六折等权）

模型	Raw-FC PCC	时间残差 PCC	条件个性 PCC	Endpoint RMSE	Raw-FC RMSE
rank-32 时间模型	0.44409	0.46594	0.43923	0.42070	0.39753
同阶容量静态 MLP	0.43043	0.46198	0.42848	0.42192	0.40220
GRU free rollout	0.41595	0.45169	0.40720	0.43018	0.41061
线性状态 free rollout	0.39372	0.43047	0.38953	0.44876	0.42792
Metadata core	0.39930	0.43771	0.38701	0.44323	0.42248

GRU 与 rank-32 时间模型相比，Raw-FC、时间残差和条件个性 PCC 的差值依次为 -0.02814 、 -0.01425 和 -0.03202 ，三项均为 0/6 折正向。Endpoint 和 Raw-FC RMSE 又分别恶化 $+0.00948$ 与 $+0.01309$ ；线性状态模型更差，故两个动态候选均 **未通过**。

GRU 胜过 metadata core，也胜过同架构的整板时间置乱和轨迹错配对照，说明它利用了真实时间顺序与正确条件身份。但不含 recurrent state 的静态 MLP 仍比 GRU 高 $+0.01448$ Raw-FC、 $+0.01029$ 时间残差和 $+0.02128$ 条件个性 PCC，且 RMSE 更低。因此当前证据只支持“条件与时间之间存在可学的非线性映射”，不支持“递归状态转移带来额外动力学规律”。GRU 与线性状态模型不进入当前路由；后续通过 grouped rolling-origin，在只读取一次真实前缀的条件下继续验证动态预测。

该结论仅限于 Protocol A 的 384 蛋白小规模验证。它促使本研究进一步执行 Protocol B grouped rolling-origin；两种任务的输入不同，不能把后者的结果倒写成 Protocol A 成功。

4.2.3 Grouped rolling-origin：真实前缀有效，递归仍未胜出

第二轮实验将完整的菌株 $\times$ 化合物 $\times$ 培养基 $\times$ 温度条件作为分组单位，进行五折留出。在 30、60、90 或 120 分钟读取该条件一次真实蛋白状态，投影到每折独立拟合的 rank-32 潜空间；之后预测至 240 分钟的全部后缀，不再读取任何中间真值。首轮仍使用以响应无关规则固定的 384 蛋白面板。比较对象包括前缀残差保持、终点原谱保持、同参数量静态前缀 MLP、线性状态转移、GRU、整板时间置乱、source $\times$ instrument 分层时间置乱、前缀身份错配及仅使用生物条件的批次消融。

表 9: Grouped rolling-origin 384 蛋白验证 (all-suffix, 五折等权)

模型	Raw-FC PCC	时间残差 PCC	条件个性 PCC	Endpoint RMSE	Raw-FC RMSE
前缀保持基线 (0.75 保持)	0.45214	0.35938	0.43712	0.46665	0.42147
线性状态自由滚动	0.46182	0.43716	0.44562	0.44805	0.40282
GRU 自由滚动	0.48523	0.44681	0.46994	0.43356	0.38614
同参数量静态 prefix MLP	0.49686	0.45715	0.48322	0.42594	0.37830

GRU 相对前缀保持基线的 Raw-FC、时间残差和条件个性 PCC 分别提高 +0.03310、+0.08743 和 +0.03282，三项均 5/5 折为正；Endpoint 与 Raw-FC RMSE 分别改善 -0.03309 与 -0.03533。它也稳定胜过时间置乱和前缀错配。增益能跨四个截止时间、两类仪器关系及四个数据来源保留；按整板聚类 bootstrap 后，时间残差增益的 2.5% 分位数仍为 +0.05008。因此，“正确的真实截止点状态包含可迁移的未来信息”有较强证据。

但 GRU 相对同信息、参数量误差小于 10% 的静态 prefix MLP，Raw-FC、时间残差和条件个性 PCC 反而低 0.01162、0.01033 和 0.01328，三项均为 0/5 折胜出，RMSE 也全部更差。线性状态模型同样被静态网络超过。因此递归候选仍 **未通过**：本轮没有证明隐藏状态逐步滚动比“当前状态 + 目标时间 → 未来状态”的直接非线性映射更好。

静态 prefix MLP 是该实验中的最强比较对象：相对前缀保持基线的 Raw-FC、时间残差和条件个性分别提高 +0.04472、+0.09776 和 +0.04610，四类 PCC 与 RMSE 均在 5/5 折改善。由于该实验的主检验对象是递归候选，静态模型随后通过独立归因实验确认。

对“可交互虚拟酵母”的直接启发是：当前更可行的原型是在少量检查点进行真实蛋白测量，并用观测状态更新后续预测，而不是将 GRU 解释为连续细胞模拟器。它属于状态条件的 few-shot 预测，不适用于完全不给同条件蛋白前缀的新药 zero-shot 场景。

4.2.4 静态前缀确认实验：只改善未来变化，不改善绝对响应

为判断静态 MLP 的收益究竟来自真实前缀，还是仅来自条件与目标时间，独立确认实验比较正确前缀、同容量 condition+time-only、前缀置零推理、置零后重训及身份错配；两主模型参数量分别为 7,898 与 7,904，差异仅 0.076%。表 10 使用同一 384 蛋白、同一五折 grouped rolling-origin 和同一评分路径。

表 10: 静态 prefix v3: 正确前缀相对同容量 condition+time-only 的确认结果

指标	Condition + time	正确 prefix	差值	正向折
Endpoint PCC	0.98733	0.98713	-0.00020	—
Raw-FC PCC	0.50218	0.49686	-0.00533	0/5
时间残差 PCC	0.36874	0.45714	+0.08840	5/5
条件个性 PCC	0.48931	0.48322	-0.00609	0/5
Endpoint RMSE	0.42267	0.42594	+0.00327	—
Raw-FC RMSE	0.37490	0.37830	+0.00340	—

正确前缀相对身份错配在 Raw-FC、时间残差和条件个性上分别提高 +0.06762、+0.11191 和 +0.07459，且均为 5/5 折正向；相对前缀置零推理也全面更好，说明网络确实使用了前缀信息。可是，当无前缀模型从头公平重训后，正确前缀只在“未来状态相对当前状态的变化”上有净收益，绝对 Raw-FC、Endpoint 和条件个性反而略差。因此，**真实前缀适合辅助预测未来差分，尚不能替代绝对终点分支**。该分支不扩展到 5,243 蛋白全面板。

4.2.5 多目标损失与高响应蛋白验证

多目标实验让训练损失直接约束 FC、残差与高响应蛋白。输入为菌株、药物、培养基、温度和时间；输出为按表头哈希预先固定的 384 蛋白评估面板，其中每折有 325–327 个坐标通过 fold-local 缺失规则。endpoint-only 与 multi-objective 使用完全相同的五折、rank-16 basis、网络、初始化、优化器和训练轮数，只改变损失；多目标权重只在各 outer-fit 内部选择。表 11 报告 multi-objective 减 endpoint-only 的同协议差值。

表 11: 多目标训练的 384 蛋白 grouped OOF 验证（候选减 endpoint-only）

场景	Raw-FC PCC	Context residual	Drug residual	Raw-FC RMSE	高响应 RMSE	技术判定
整种药物未知	+0.01035	0.00000	+0.00461	-0.00350	-0.01134	未通过: 新药个性无增益，VR 远离 1。
未见 K_{bio} 组合	+0.01187	+0.01550	+0.00457	+0.00031	-0.00986	未通过: Raw-FC RMSE 硬门槛未过。

两场景的 Raw-FC PCC 都是 5/5 折提高。whole- K_{bio} 的 signed Precision@K、Recall@K 和 macro AUPRC 又分别提高 +0.00612、+0.00388 和 +0.00380；whole-chemical 的高响应 RMSE 改善 -0.01134。这说明多目标训练确实改变了模型参数，并把一部分收益移向扰动响应及变化最大的蛋白，而不只是换了一套评分方式。

整种药物未知时，未见药物 one-hot 统一落到 unknown，模型没有结构或机制描述符，同一背景下不同新药仍得到相同条件表示，因此 context residual 增益严格为零；signed Recall@K 也

只有约 0.173。whole- K_{bio} 虽然多数响应指标改善，Raw-FC RMSE 却微增 0.00031，未通过预设门槛。故当前主路由不变；后续将评估预先定义的混合或幅度校准，并加入可泛化的药物描述符。

最终评分实现统一使用真值与预测的共同有效掩码，并要求每个“分组 $\times$ 蛋白”单元至少包含两个有限观测。早期不满足该合同的结果全部作废；修正版通过合成测试和独立复算。

4.2.6 公平条件架构对比：仅使用条件 metadata 的 MLP 未超过 Ridge

为检验非线性架构能否在相同输入和评价协议下优于 Ridge，实验预先固定拆分、模型与超参数。所有候选读取相同的生物条件 metadata，预测相同的 384 蛋白评估面板，使用相同的 whole-chemical 与 whole- K_{bio} 五折、pairwise direct measured-control 评分和 endpoint-only 训练目标。比较对象为 biological-only Ridge、直接多输出 MLP、rank-16 低秩 MLP，以及把共享条件、菌株、化合物和交互项显式拆开的 residual MLP。三种神经网络均控制在约 6,000 个参数，并以三个随机种子重复；Ridge 是更强但并非等参数量的线性参考。biological-only Ridge 不包含 source 和 instrument，仅用于架构对比，并非当前主模型。由于 chemical-to-vehicle 映射尚未提供，Raw-FC 使用 pooled DMSO/Water matched-control，仅作为模型比较口径。表中均为“候选减 Ridge”；PCC 差值越大越好，RMSE 差值越小越好。

表 12: 公平条件架构验证：候选相对 biological-only Ridge 的差值

场景	候选	Raw-FC PCC	Context residual PCC	条件个性 PCC	Endpoint RMSE	判定
整种药物未知	Direct MLP	-0.02682	0.00000	+0.00007	+0.01490	未通过
整种药物未知	Low-rank MLP	-0.02677	0.00000	+0.00010	+0.01591	未通过
整种药物未知	Residual MLP	-0.03551	0.00000	-0.02816	+0.03847	未通过
未见 K_{bio} 组合	Direct MLP	-0.00938	-0.02569	-0.00856	-0.00343	未通过
未见 K_{bio} 组合	Low-rank MLP	-0.00496	-0.00477	-0.00181	-0.00692	未通过
未见 K_{bio} 组合	Residual MLP	-0.09351	-0.15670	-0.10327	+0.10766	未通过

所有神经网络均优于“将训练目标随机错配给条件”的负对照，随机种子稳定性也通过，说明网络学到了训练条件与蛋白响应之间的关联；但这些关联没有比 Ridge 更好地迁移到留出的实体。whole- K_{bio} 的 low-rank MLP 在 Endpoint RMSE 和 drug residual PCC 上分别改善 0.00692 和 0.01235，VR 也更接近 1；但 Raw-FC、context residual 和条件个性同时下降，因此未通过联合门槛。

whole-chemical 的 context residual 在四个模型中都为 0.07501，候选相对 Ridge 的增益严格为零。原因是这些模型只有化合物身份编码：一种化合物被完整留出后，其身份表示统一回退为 unknown，模型无法区分不同新药。本实验中的身份型 MLP 未能改善新药 OOD；该结论不适用于带化学结构、靶点或机制表征的模型。三种候选均不进入 5,243 全面板验证；低秩 decoder 保留为外部知识 encoder 的输出端。

独立重算复现了全部聚合指标；该实验仅使用训练集内部 OOD 评价。结果表明，在相同协议下，增加非线性复杂度尚未带来优于 Ridge 的 OOD 条件响应。

4.2.7 外部公共知识 Transformer：结构覆盖子集呈现弱信号，全实体主分析未晋级

在身份型 MLP 未通过后，本研究进一步检验“外围知识 + 跨模态交互”是否能够补足未见实体信息。候选输入包括 biological metadata、严格唯一映射的 ChEBI 化学结构，以及由 SGD/GO、SGD 中的 Reactome 引用与 STRING 邻域构成的 326 维公共蛋白特征；该特征再压缩成七个全局汇总 token，而非七条命名通路。输出为同一 384 蛋白评估面板的 rank-32 终点预测。严格结构覆盖为 train 药物 22/37；蛋白 token 的别名唯一映射对完整表头覆盖 5,094/5,243，在评估面板中覆盖 373/384。菌株公共资源虽可映射 3/4 个训练菌株，但当前实验不启用菌株公共视图，所有菌株公共 token 均置为 missing[26, 23, 24, 27]。

所有未映射实体均以全零公开特征和显式缺失标记进入模型。全实体主分析（有映射与未映射实体均纳入）包括 22 个有严格结构映射和 15 个使用缺失标记的非对照训练药物。两层、四头的小型 Transformer 同时与直接终点 Ridge、同容量知识 MLP、仅使用实验条件的 Transformer、公共知识身份置乱、推理时实体错配和去除蛋白知识等对照比较。候选与同容量 MLP 的最大参数差为 0.3506%。表 13 报告候选相对每项指标中最强主基线的差值；PCC 差值越大越好，RMSE 差值越小越好。

表 13: 外围知识 Transformer 的 384 蛋白全实体 OOD 结果

场景	Raw-FC PCC	Context residual PCC	Drug residual PCC	条件个性 PCC	Endpoint RMSE	技术判定
整种药物未知	-0.00442 (1/5)	-0.00425 (1/5)	-0.00505 (1/5)	+0.00038 (2/5)	-0.00258	未通过
未见 K_{bio} 组合	-0.01085 (0/5)	-0.02885 (0/5)	+0.00217 (5/5)	-0.01122 (0/5)	+0.00469	未通过

主表采用更保守的“逐折、逐指标最强主对照”口径。敏感性分析对每个指标选取五折均值最优、并在各折固定不变的对照模型；此时 whole-chemical 的 context residual、条件个性和 Endpoint RMSE 差值分别为 -0.00094、+0.00088 和 -0.00290，whole- K_{bio} 的结论也不变。两种口径均未通过全面验证门槛。whole- K_{bio} 的 drug residual 虽为 5/5 折正向，但 +0.00217 低于预设的 +0.003 实质增益门槛。

结果提示结构已覆盖药物子集可能包含值得继续验证的信号：候选相对 metadata-only Transformer 的 Raw-FC、drug residual 和条件个性分别提高 +0.02349 (5/5)、+0.00328 (4/5) 和 +0.00666 (4/5)。在全部 whole-chemical 条件中，Raw-FC 相对 metadata-only 也提高 +0.01474 (5/5)。但负对照尚未形成一致证据，因此不能作机制归因，也不能外推到全部药物。

候选在两种全实体 OOD 的 Raw-FC PCC 上均低于直接 Ridge，且联合门槛均未通过；相对仅使用实验条件的 Transformer，条件个性增益在整种药物未知中只有 +0.00183，未见 K_{bio} 组合时的 Raw-FC/个性也只有 +0.00303/+0.00389，均低于预设门槛。相对外部知识置乱对照，未见 K_{bio} 组合时的 Raw-FC 和个性为 -0.00020/-0.00018；公共蛋白特征相对移除蛋白知识的消融，Raw-FC 又分别为 -0.00471 和 -0.00018。七个全局摘要未显示可归因增益，可能因压缩过粗，尚未证明模型利用了正确的蛋白网络关系。

独立重算复现了全部聚合指标；该实验仅使用训练集内部 OOD 评价。当前 Transformer 不

进入 5,243 全面板验证。后续优先提高严格药物结构覆盖，并把蛋白知识由七个全局摘要改成可消融的功能模块或药物靶点到蛋白网络的局部路径。

4.2.8 公共蛋白知识表征聚类 multi-head：完整条件留出中神经模型改善，但分组无增量价值

本研究使用冻结的公共蛋白特征做确定性聚类：7,504 个公共酵母蛋白仅依据 GO、Reactome 引用和 STRING signed-hash 表征分为 8 个匿名组；384 蛋白面板中有 11 个别名无法唯一连接，进入显式 missing 组 [23, 24, 27]。聚类与面板分组均不读取比赛响应。实验比较正确分组 multi-head、同容量 single-head，以及保持组大小且令所有已映射蛋白换组的 assignment-deranged multi-head。五折与两个随机种子构成 10 个配对比较。表中为“正确分组减对照”；PCC 差值越大越好。

表 14：公共功能表征聚类 multi-head 的预声明配对证据

OOD 场景	对照	Raw-FC PCC 差值	正向对	条件个性 PCC 差值	正向对	判定
整种药物未知	同容量 single-head	-0.008485	2/10	+0.001213	6/10	未通过
整种药物未知	分组错配 multi-head	-0.003818	4/10	+0.000782	5/10	未通过
未见 K_{bio} 组合	同容量 single-head	-0.005013	1/10	-0.003330	1/10	未通过
未见 K_{bio} 组合	分组错配 multi-head	+0.000279	4/10	+0.001107	6/10	未通过

whole- K_{bio} 中，正确分组 multi-head 的 Raw-FC PCC 为 0.378682，数值上高于 Ridge 的 0.336601；但同容量 single-head 达到 0.383695，错配分组也达到 0.378404。由于同容量单头和错配分组模型达到相同或更高水平，该收益不能归因于正确公共功能分组，可能来自一般神经架构或优化差异。whole-chemical 中，正确分组的 Raw-FC PCC 为 0.231256，低于 Ridge 的 0.256278 和 single-head 的 0.239741。预设门槛要求正确分组在两个场景都胜过两类对照、每项至少 7/10 个配对为正且条件个性不下降；所有条件均失败。

独立重算复现了全部聚合指标；正确与错配多头参数量相同，single-head 参数差最大 0.7963%。该匿名分组实现不进入 5,243 蛋白全面板验证。由于现有 signed-hash 表征不能直接还原为可命名的通路归属，下一项实验改用可审计的 GO-slim 多标签归属，并保留分组错配负对照。

4.2.9 命名酵母 GO-slim：正确通路归属出现局部信号，但未超过简单模型

为检验匿名哈希分组是否掩盖了真实通路结构，本研究使用 GO Basic 2026-06-19 与 SGD GAF 2026-06-17 构建命名、多标签的酵母 GO-slim biological-process 归属 [23, 22]。冻结的 384 蛋白面板中，372 个 SGD 别名能够解析；按每个通路在面板中覆盖 4–192 个蛋白的规则保留 77 个非根通路，覆盖 324/384 个蛋白，共形成 977 条多标签归属边。代表性模块包括有丝分裂细胞周期、胞质翻译、DNA 修复、蛋白折叠、氧化应激、细胞呼吸、跨膜运输和细胞壁组织。

候选模型通过命名通路共享输出响应，同时保留逐蛋白残差分支。比较对象包括强 metadata Ridge、同容量 single-head 和通路归属置换 token；置换对照保持每个通路大小、整体覆盖率以及蛋白归属度数分布。表 15 汇总五折与两个随机种子的均值。Raw-FC PCC 越高越好；“候选减对照”为正确命名通路模型相对相应对照的配对差值。

表 15: 命名酵母 GO-slim 输出分支的 384 蛋白 OOD 结果

场景	候选 Raw-FC PCC	减 Ridge	减同容量单 头	减归属置换	候选条件个性 PCC	判定
整种药物未知	0.23160	-0.02467 (0/10)	-0.00905 (3/10)	+0.00500 (7/10)	0.23786	未通过
未见 K_{bio} 组合	0.34925	+0.01265 (10/10)	-0.01613 (0/10)	+0.00010 (5/10)	0.34156	未通过

整种药物未知时，正确通路归属相对归属置换的 Raw-FC PCC 提高 +0.00500，表明可命名结构包含弱信号；但它仍低于 Ridge 和同容量单头。未见 K_{bio} 组合时，候选虽高于 Ridge，却低于同容量单头，并与归属置换基本持平。预设联合门槛因此失败，该输出侧通路共享不扩展到 5,243 蛋白。独立重算复现了聚合指标；该实验仅使用训练集内部 OOD 评价。

该结果不表示通路知识整体无效，而是限定了其使用方式：输出通路归属能够说明哪些蛋白共同参与过程，却不能说明一个未见药物将作用于哪些过程，也不能说明一个未见菌株具有哪些功能差异。因此，后续实验分别把药物靶点到局部蛋白网络和菌株变异负担放在输入侧，并以实体身份置换、结构错配和同维随机特征检验增益能否归因于正确生物知识。

4.2.10 药物靶点到 STRING 局部网络：当前实现未通过严格 OOD 门槛

该实验在固定 384 蛋白面板上比较直接 metadata Ridge、化学结构特征、药物靶点局部网络，以及靶点身份置换、度匹配网络节点错配、蛋白坐标错配和等容量随机特征。STITCH 到 STRING 的严格靶点映射覆盖训练集中的 14/37 个药物，STRING 覆盖面板中的 360/384 个蛋白；主结果采用纳入映射缺失分支的全实体五折均值，覆盖子集不参与晋级判定 [28, 27]。

表 16: 药物靶点局部网络的全实体 OOD Raw-FC 结果

场景	直接 Ridge	靶点局部网络	差值与判定
整种药物未知	0.25756	0.24894	-0.00862, 未通过
未见 K_{bio} 组合	0.33672	0.32635	-0.01037, 未通过

整种药物未知时，候选的 context-residual PCC 相对预设直接/结构参考提高 +0.00416，但低于 +0.005 门槛，且正确局部网络的绝对值 0.07806 低于度匹配网络错配的 0.07846，不能归因于正确网络。限制到靶点已覆盖条件也未挽救候选：整种药物未知与未见 K_{bio} 组合的 Raw-FC 分别为 0.22541 对 0.24667、0.28205 对 0.30878（候选对直接 Ridge）。因此，该分支不进入正式路由，也不扩展至 5,243 蛋白；结论仅拒绝当前 STITCH 阈值、STRING 一步传播、rank-32 decoder 与稀疏映射的组合，不能泛化为“药物靶点知识无用”。STITCH 派生特征当前仅限研究性实验。

4.2.11 真实菌株变异与 CNV: LoF/移码存在可信弱信号但未晋级

该实验将 Peter 等 (2018) 资源中的功能缺失 (LoF)、移码、基因存在/缺失与拷贝数聚合成 64 个命名 GO 生物过程通路负担，再用仅由公共菌株拟合的 PCA 得到 8 维菌株特征 [21]。权威精确映射覆盖训练集中的 3/4 个菌株、已发布六株中的 5/6；未映射菌株严格回退 metadata Ridge。第一轮在探索面板比较五通道联合、CNV/基因存在性与 LoF/移码，结果见表 17。

表 17: 菌株公开变异表示的第一轮 whole-strain 结果（相对 metadata Ridge）

输入分支	Raw-FC PCC 增量	Endpoint RMSE 变化	判定
五通道联合	+0.00234	+0.00735	未通过
CNV/基因存在性	-0.02248	+0.05386	明确失败
LoF/移码	+0.00701	-0.00066	进入独立确认

由于 LoF/移码候选是在探索面板上选出的，确认实验另冻结了与其零重叠、按响应无关的确定性规则选择的 384 蛋白独立确认面板。

该面板的整株留出全实体 Raw-FC PCC 增量为 +0.007003，已覆盖菌株子集为 +0.009337。正确菌株身份在六种分配中排名第一，并分别高于同维随机特征 +0.003680、高于基因-通路错配 +0.007369。这些结果说明正确的公开菌株身份与 LoF/移码通路结构携带可迁移的菌株侧信息，而不只是增加了八个变量。

但预设晋级条件并未全部通过：三个已覆盖菌株仅 2/3 折为正；Endpoint 与 Raw-FC RMSE 均增加 +0.001107；条件个性 PCC 变化约为零；未见 K_{bio} 组合时 Raw-FC PCC 仅增加 +0.000360。因此，该结果是可信但尚不稳定的菌株场景信号，并非可部署的六菌株编码器，暂不进入正式路由。当前公共资产的再分发许可尚待源站条款确认，故仅用于研究验证。

随后对嵌套收缩设想进行了数值执行前的保守停止式 (fail-closed) 可识别性审计，而不是把它作为新的模型结果。第三个 384 蛋白独立面板仅依据表头、以响应无关规则锁定，并与探索面板和独立确认面板保持零重叠；但训练集只有 3/4 个菌株具有权威映射，整株留出的内层拟合子集中仅剩 1-2 个已映射公共菌株样本。由此，名义上的 PCA8 特征在内层拟合中实际秩不超过 2，且完全落在菌株 one-hot 的线性张成空间内，对已有 metadata 设计矩阵的增量秩为 0。在这种条件下，收缩参数 λ 的选择主要反映 Ridge 惩罚与参数化约定，不能构成独立的基因组到响应证据。因此审计按预设规则停止；在读取任何官方蛋白响应数值之前即判定该方案当前不可识别，没有产生新的数值模型结果。

4.2.12 缺失阈值与实测对照校准

所有阈值只决定主模型拟合哪些坐标，其余坐标始终使用训练集补全基线，不会减少提交列。表 18 中的坐标数与训练集有效观测单元覆盖来自直接数据统计；阈值比较统一采用直接实测对照、共同重复掩码和两套独立分组，在整种药物留出与未见 K_{bio} 组合中评价。

表 18: 完整 5,243 蛋白的缺失阈值坐标与覆盖统计

缺失阈值	主拟合坐标	基线补全坐标	有效单元覆盖	当前解释
50%	3,892	1,351	93.819%	修正版 Raw-FC/个性均退步。
70%	4,235	1,008	97.499%	修正版总体退步，未通过。
80%	4,422	821	98.733%	冻结参考，当前保留。
90%	4,633	610	99.570%	全部 5/5 略好，但低于 +0.003 门槛。

90% 相对 80% 的 Raw-FC 增益在整种药物未知约为 +0.00049, 在 whole- K_{bio} 约为 +0.00200; 条件个性增益最高 +0.00206, 方向稳定但不足预设实质门槛。因此**保留 80% 工程参考**; 这一选择不代表 80% 在生物学或每个单项指标上最优。

严格 exact-control 的键匹配覆盖仍然有效: data source、instrument、plate、菌株、培养基、温度和时间均相同; treated-row 的 pooled、DMSO-only 和 Water-only 匹配率分别为 99.764%、96.416% 和 92.024%。修正版直接把显式聚合的 measured control 当作终点预测, 不再由 truth 反推: 两套分组和两个场景的 Endpoint PCC 为 0.98598–0.98604, RMSE 为 0.41599–0.41890; Raw-FC、context、drug、条件个性 PCC 与 VR 均严格为 0。这说明它只恢复稳定背景, 不是扰动预测器。

在推理期确实拥有 exact measured control 的受限场景中, 本研究进一步用 nested OOF 拟合逐蛋白收缩校准:

$$\hat{y}_{i,p}^{\text{cal}} = y_{i,p}^{\text{ctrl}} + a_p \left(\hat{y}_{i,p}^{\text{ridge}} - y_{i,p}^{\text{ctrl}} \right) + b_p,$$

(40)

其中 a_p 向 1 收缩、 b_p 向 0 收缩, 所有参数只由 outer-fit 内部的无泄漏预测估计。最终实现对每个 condition–protein 固定处理与对照均有限的共同 replicate 掩码, 并在同一掩码上分别聚合 endpoint 与 control; 早期不满足该共同掩码合同的结果全部作废。修正版在两套独立分组中重新验证, 始终输出 5,243 个坐标。表 19 报告候选相对同折 Ridge 的全面板差值。

表 19: Pairwise exact-control affine 的 5,243 全面板确认结果

分组	场景	Raw-FC	Context	Drug	条件个性	Raw-FC RMSE	候选 VR
分组 A	整种药物未知	+0.01755	+0.00928	+0.00709	+0.01341	−0.15900	0.507
分组 A	未见 K_{bio} 组合	+0.01834	+0.01189	+0.01312	+0.01701	−0.09652	0.513
分组 B	整种药物未知	+0.01797	+0.00874	+0.00705	+0.01376	−0.16250	0.477
分组 B	未见 K_{bio} 组合	+0.01872	+0.01131	+0.01335	+0.01717	−0.09757	0.514

四组比较中的 Raw-FC、context residual、drug residual 与条件个性均为 5/5 折改善, RMSE 也均下降; 正确分支同时在 Raw-FC 和条件个性上胜过目标打乱与对照身份错配。目标打乱分支的 RMSE 有时反而更低, 说明相当一部分 RMSE 改善来自普遍收缩; 支持条件信号的关键证据是正确配对在两套分组中稳定提高 Raw-FC 与条件个性, 而不是低 RMSE 本身。因此, 在**同一 replicate 成对定义处理–对照差值**的估计目标下, 该方法达到预设门槛, 但只保留为有实测 exact control 时的条件校准。

聚合敏感性分析分别使用所有有限 endpoint replicate 和所有有限 control replicate; 在 whole- K_{bio} 中, Raw-FC 与条件个性虽仍提高 +0.01989 与 +0.01804, VR 却从 1.15243 降到 0.48376, 比 baseline 更远离 1, 因此未通过幅度门槛。由此, control-affine 仅作为 pairwise estimand 下、有实测 exact control 时的条件分支; 若推理阶段不给同条件实测 control, 式 40 不启用。

4.2.13 未通过的候选同样定义了研究边界

表 20: 代表性拒绝实验及其信息价值

候选	关键结果	技术判定
Pair-OOD 低秩 ANOVA	Raw-FC +0.000996; interaction residual +0.030873; individuality +0.009912	VR 0.166 < 0.20, 药物身份 $p = 0.846$ 、菌株身份 $p = 0.338$; 未证明正确实体配对。Pair-OOD 也不是双重未知。
名称/结构/靶点 zero-shot	已测试名称语义、SMILES、 Morgan、MoLFormer、ChEBI、 STITCH、BindingDB、Y2T、 MOSAIC、HOP/Y5K 等	没有形成同时通过 Raw-FC、条件残差、RMSE、折稳定性和负对照 的药物特异专家。
单模型 LLM 机制特征包	context residual +0.027857, 但 Raw-FC -0.000992; 身 份/符号 null $p = 0.391/0.406$	说明低维 decoder 有容量, 但未证明语言因果链包含可迁移语义。
双模型 LLM 机制特征	Qwen+Gemma 共识: Raw-FC -0.01414; context -0.01475; Endpoint RMSE +0.12595	0/5 折 Raw-FC 改善, 且低于单模与随机特征; 不使用 RAG 的特 征不进入主模型。
LINCS RNA→ 酵母 GO 桥	macro PCC gain -0.00302; MSE 改善 0.956%, 仅 2/5 折 为正	未达到预设的 1% MSE 门槛, 不进入主模型; 保留为跨组学扩展方 向。

这些负结果共同指向一个清晰瓶颈: 模型能够学习蛋白响应的低维结构, 但尚缺少可靠的“全新药物条件 → 响应系数”映射。公共结构或知识在自身任务上有信号, 并不自动意味着能迁移到比赛总蛋白响应。

4.2.14 不确定性有局部价值, 但不能牺牲点预测

条件异方差潜空间高斯与同参数量确定性 MLP 已在两个五折 OOD 场景中比较。预测均值用于 Endpoint/Raw-FC, 预测方差则与 fit-only constant、held-row shuffle 和 sampling-off 对照比较。表 21 将“点预测是否保真”和“方差是否知道哪里困难”分开报告。

表 21: 条件异方差模型：点预测变化与不确定性证据

场景	Raw-FC PCC	Context PCC	个性 PCC	不确定性相对对照	总判定
整种药物未知	-0.00564	0.00000	-0.00310	胜 shuffle: NLL +0.02594、Spearman +0.28749; 但 NLL 比 constant 差 0.01935	未通过 : 点预测与绝对校准 未过。
未见 K_{bio} 组合	-0.00786	-0.01049	-0.01022	胜 constant: NLL +0.05173、Spearman +0.61310; 胜 shuffle: +0.07437/ + 0.52541	未通过 : 方差通过, 点预测 未过。

whole- K_{bio} 的 90% 区间覆盖率为 0.90455, 误差-方差 Spearman 为 0.441; 方差错配到别的条件后降为 -0.084。这表明不确定性 head 识别到一部分“哪些组合更难”, 而不是所有条件给同一误差条。然而 Gaussian NLL 同时改变了均值 head 的优化折中, 使 Raw-FC 和条件个性下降, 因此整体门槛仍失败。当前用途是冻结确定性均值, 只在交叉拟合残差上训练 stop-gradient uncertainty head, 用它安排主动实验或显示置信度; 这一模型不等同于完整 cVAE 或细胞模拟器。

4.2.15 公开数据实验的正向证据与限制

公共 PXD 数据上, 实测 phospho readout 到 total-proteome readout 的桥接模型使 MSE 改善 10.17%, identity permutation 的经验 $p = 0.004975$ 。这证明“给定新药的实测磷酸化响应后, 预测其总蛋白响应”具有可学信号; 但上游的 structure→phospho 前端没有通过, 因此整条链仍需新药实测 phospho, 属于辅助测量或 few-shot, 不是 zero-shot。

Y5K 可用于学习蛋白协方差与 decoder, PXD034997 可演练化合物响应, PXD016567 可演练菌株/温度 OOD; 但这些公共数据到比赛输出的直接迁移尚未通过严格门槛。目前公共数据管线证明了局部桥接信号, 尚未证明其能够提高最终新药预测。

公共机制桥进一步进行了 public-only 复现实验。CGM 到 Y5K 的 ORF 对齐分数为 0.026697, ORF 与 assignment 随机化检验分别得到 $p = 0.025$ 和 $p = 0.005$, 说明存在弱但非随机的基因选择性结构; 然而 learned structure 候选的 whole-scaffold macro latent PCC 为 0.082952, 低于简单 Tanimoto kNN 的 0.099451, 因此当前 encoder 不进入比赛路由。

主动 few-shot 校准已完成探索性实验: 对每个新条件提供四个精确支持点时, GP-only 相对无支持基线在多个响应指标上有改善; 但预先指定的 ensemble 低于 GP-only, 且支持点选择后的评估并非独立前瞻盲测, 因此未通过主门槛。该结果支持继续研究“少量真实测量校准新条件”, 但不能等同于 zero-shot 新药预测。

4.2.16 消融验证对技术方案的影响

表 22 汇总各候选模块的验证证据及其对最终技术方案的影响。

表 22: 已验证模块及当前技术决策

候选模块	已完成证据	对当前方案的改变
多目标 loss 与 DEP	两类 OOD Raw-FC 均 5/5 小幅提高, 高响应误差下降; 均未通过完整预设门槛	评价指标与候选 loss 保留, 主预测器不替换。
公平 MLP 架构对比	Direct、low-rank 与 residual MLP 均胜过目标错配负对照, 但未超过 biological-only Ridge	不进入全面板验证; 低秩 decoder 保留给可泛化的外围知识表征。
source、instrument、plate 校准	source+instrument 跨未见 plate 保留; plate 收益反转	core 加入 source+instrument, 排除 plate。
50/70/80/90% 缺失阈值	共同掩码的 pairwise 比较中, 90% 的稳定增益低于 +0.003	保留 80% 工程参考与 4,422 + 821 输出合同。
Matched control 与后处理	pairwise 口径达到门槛, 另一无泄漏聚合口径的幅度门失败	仅保留为“推理期有实测 control”的条件校准, 不属于默认预测分支。
生成式/不确定性	whole- K_{bio} uncertainty 通过, 但点预测下降	只作主动实验与置信度旁路, 不替换预测均值。
公共机制与结构桥	CGM-Y5K 有弱非随机对应; learned encoder 低于 Tanimoto	保留公共数据迁移检验, 不接入当前编码器。
外围知识 Transformer	覆盖药物子集提示可能有结构信号, 但负对照不一致; 全实体主分析未超过强 Ridge	不进入全面板验证; 后续提高结构覆盖并改用功能模块或局部网络 token。
公共功能表征 multi-head	whole- K_{bio} 神经模型高于 Ridge, 但正确分组低于同容量单头, 且未稳定胜过分组错配	匿名分组不进入全面板验证; 后续测试可逆、可命名且可错配验证的通路归属。
命名酵母 GO-slim	整种药物未知时相对归属置换 Raw-FC 提高 +0.00500, 但低于 Ridge 与同容量单头; 未见 K_{bio} 时与置换对照基本持平	输出侧通路共享不进入全面板验证; 输入侧知识另行独立验证。
药物靶点到 STRING 局部网络	全实体 Raw-FC 为 0.24894 对 Ridge 0.25756 (整种药物留出), 以及 0.32635 对 0.33672 (未见 K_{bio} 组合); 局部上下文残差增益低于门槛且网络错配更高	当前稀疏靶点网络不进入正式路由; 保留“提高靶点覆盖与证据质量后重测”的研究方向。
菌株基因组/CNV 通路负担	五通道联合与 CNV/基因存在性分支失败; LoF/移码在独立确认面板的整株留出 Raw-FC 提高 +0.007003, 身份排名 1/6, 但仅 2/3 个已覆盖菌株的折为正且 RMSE 增加 +0.001107	保留为可信但尚不稳定的菌株侧研究信号, 暂不进入正式路由。
开放权重 LLM 与 LoRA	不使用 RAG 的 Qwen+Gemma 特征在五折中稳定退化	当前特征不进入主模型; 后续先建设可追溯 RAG。
5,243 维提交安全	行列顺序、有限值、数值空间与故障注入测试通过	保守停止式输出合同进入工程主线。

4.2.17 最终模型路由与研究结论

当前可复现方案可写成：

$$\begin{aligned} \text{最终模型路由} = & \text{Metadata core} + \text{新菌株 residual expert} \\ & + \text{已见 base 的时间 expert} + \text{新药受限共享校准} \\ & + g_c \text{ pairwise exact-control affine.} \end{aligned} \quad (41)$$

同时对双重未知和未通过门槛的候选执行回退。这里的“新药受限共享校准”只校正跨药物共享偏差，不代表恢复了新药机制或药物个性； $g_c = 1$ 仅在推理期提供满足同一 replicate-pair 合同的实测对照时成立，否则为 0。

综合实验得到以下结论：

- 仅依赖总体 Endpoint 会严重高估模型是否学会条件响应；
- 共同掩码的成对比较支持保留 80% 工程参考，并始终用训练集补全基线补满 5,243 个坐标；
- 新菌株和新时间在严格 OOF 中获得可重复的条件特异增益，并形成带适用范围的候选分支；
- 真实截止点状态改善后续预测，但递归模型未超过公平静态对照，因此递归动力学分支不进入最终路由；
- 静态前缀确认已完成：真实前缀只稳定改善未来差分，不能替代绝对终点或 Raw-FC 分支；
- 多目标训练与高响应蛋白评价指标已实现并出现稳定弱增益，但两个 OOD 场景均未通过完整晋级门槛；
- Direct、low-rank 和 residual MLP 的公平对比已完成；它们学习了条件关联，却均未超过 Ridge，说明仅使用条件 metadata 的身份编码不足以解决新药 OOD；
- 带 ChEBI 与 GO/STRING 外围知识的 Transformer 已完成全实体主分析；覆盖药物子集提示弱结构信号，但两类 OOD 主门槛和知识归因门槛均失败，不进入全面板验证；
- 公共蛋白知识表征聚类 multi-head 已完成同容量和分组错配验证；未见 K_{bio} 组合中的神经模型改善不能归因于正确 GO/STRING 分组；
- 命名酵母 GO-slim 多标签输出分支相对归属置换仅在整种药物未知中出现弱信号，但未超过 Ridge 或同容量单头，说明仅做输出侧通路共享不足以解决实体 OOD；
- 药物靶点到 STRING 局部网络已完成全实体、覆盖子集及网络错配验证；两类 OOD 的 Raw-FC 均低于直接 Ridge，局部上下文残差信号也不能归因于正确网络，因此当前实现不进入正式路由；
- 真实菌株变异通路负担已完成探索面板与独立确认面板的零重叠验证；CNV/基因存在性分支明确失败，LoF/移码在独立确认面板上具有可归因的整株留出弱信号，但逐菌株稳定性与 RMSE 未过门，因此暂不进入正式路由；
- control-affine 只在限定的 pairwise 估计口径达到门槛，另一无泄漏聚合口径的幅度门失败，因此不属于默认预测分支；

- whole- K_{bio} 的不确定性子门出现可重复的难度排序信号，但点预测与整体门槛失败；当前仅将其作为主动实验排序候选；
- Qwen+Gemma 在不使用 RAG 时生成的机制特征未通过门槛，后续 RAG 与 LoRA 需要可追溯的外部机制监督；
- 完全未见药物仍是当前主要科学瓶颈；
- 证据门控和拒绝机制比无条件堆叠复杂模型更符合 OOD 科学问题。

下一阶段的优先级依次为：确认官方 vehicle 映射、推理期 control 可用性与评分细节；获得更多彼此独立且具有权威公共映射的菌株背景，并核验 Peter 公共资产许可，再重新评估菌株基因组收缩模型；仅在获得覆盖更高、唯一解析且许可兼容的酵母靶点证据后重测药物局部网络；为 whole- K_{bio} 冻结多目标混合或幅度校准实验；冻结确定性均值并交叉拟合独立 uncertainty head；建立有来源、版本冻结的本地 RAG 后再重测机制特征。LoRA 仅在 RAG 或公共监督先通过 whole-drug 预设门槛后考虑；主动 few-shot 需要新的前瞻盲测。在静态条件模型未被公平超过前，不优先扩大 LSTM/GRU 或 Latent ODE。

5 复现、开放与合规

5.1 复现方式

每次实验记录数据角色与源文件校验值、代码和依赖版本、随机种子、交叉验证折定义、仅由拟合子集估计的统计量、蛋白掩码、基线、候选模型、负对照、聚合指标和技术判定。所有结果同时标记数据划分、对照定义、蛋白面板和聚合方式，避免直接比较不同协议下的绝对分数。

复现流程为：

1. 校验数据字段、文件校验值与 5,243 维输出合同；
2. 按 OOD 实体或完整条件身份生成分组交叉验证；
3. 在每个交叉验证折内重新估计缺失掩码、标准化、类别词表和低秩基；
4. 在相同评分单元上比较核心模型、候选模型及容量匹配负对照；
5. 汇总 Endpoint、Raw-FC、残差、条件个性、RMSE、VR 和高响应蛋白指标；
6. 仅将通过预设门槛且满足输入前提的分支写入最终路由清单。

提交程序采用**保守停止式 (fail-closed) 输出合同**：预测行顺序与官方样本合同一致；每行始终包含 5,243 个蛋白坐标；在全部训练集上，4,422 个主建模坐标与 821 个训练集补全坐标构成固定工程输出；交叉验证时则只用当前折的拟合子集重新计算掩码。合并后的输出不得包含 NaN/Inf，对数空间与原始强度空间转换须与提交要求一致。提交程序已通过行列顺序、输出宽度、有限值、数值空间转换及故障注入测试；运行环境使用依赖锁文件或容器镜像固化。

5.2 代码索引与复现边界

以下代码位置均以 Git 仓库根目录为起点，不包含本机绝对路径。复现级别定义为：**LIVE** 表示统一代码可直接执行；**SRC+AGG** 表示历史源码存在且冻结聚合证据可回放，但本轮未在统一框架中重新训练；**AGG** 表示当前仅能复核聚合证据；**BLOCKED** 表示缺少可执行源码或可识别性条件，不作源码级复现声明。

表 23: 核心方法的仓库相对代码位置

模块	统一实现位置
数据 schema 与适配	research_code/pipeline/dataset.py
对数变换、fit-only 缺失过滤与完整输出	research_code/pipeline/preprocessing.py
metadata 编码与未知类别	research_code/pipeline/metadata.py
whole-entity OOD 划分	research_code/pipeline/splitting.py
成对实测对照与共同有效掩码	research_code/pipeline/controls.py
均值与 masked multi-output Ridge	research_code/models/baselines.py
Endpoint、Raw-FC、残差、RMSE、 R^2 与 VR	research_code/evaluation/metrics.py
DEP/高响应蛋白与分支准入	research_code/evaluation/dep.py; research_code/evaluation/gates.py
公共机制轴评测	research_code/evaluation/public_axes.py
实验 Interface、运行器与注册	research_code/experiment_core/base.py; research_code/experiment_core/runner.py; research_code/experiment_core/registry.py
命令行与聚合报告	research_code/research_cli.py; research_code/reporting/writer.py
历史证据回放与有效性注册	research_code/experiment_core/legacy_evidence.py; research_code/evidence/registry.json
依赖与测试	research_code/pyproject.toml; research_code/uv.lock; research_code/tests/

表 24: 主要实验结果与代码/证据位置

实验模块	统一入口; 历史源码或冻结证据	复现级别
均值与 Metadata Ridge	code/experiments/official-dataset-local/ metadata_model/run_metadata_ridge.py; reports/complete-research-report-v9/ artifact.json	SRC+AGG
批次消融与提交合同	experiments/training-camp-completion-v1/ run_calibration_audit.py; experiments/ training-camp-completion-v1/submission_ contract.py	SRC+AGG
公平 MLP 架构比较	research_code/experiments/fair_ architecture.py; experiments/ fair-architecture-benchmark-v1/run_ experiment.py	SRC+AGG
新菌株与时间分支	code/experiments/official-dataset-local/ strain_router/run_strain_router.py; code/experiments/official-dataset-local/ time_lowrank/run_time_lowrank.py	SRC+AGG
低维动态与状态前缀	research_code/experiments/ latent_dynamics.py; experiments/ latent-dynamics-v2-rolling-origin/ run_experiment.py; experiments/ static-prefix-v3-confirmatory/run_v3.py	SRC+AGG
多目标与条件不确定性	research_code/experiments/multiobjective_ highresponse.py; experiments/ multiobjective-highresponse-v1/run_ experiment.py; research_code/experiments/ conditional_uncertainty.py	SRC+AGG
成对实测对照校准	research_code/experiments/control_ affine_pairwise.py; experiments/ control-affine-fullpanel-v2-pairwise/ run_pairwise_fullpanel.py	SRC+AGG
外围知识 Transformer	research_code/experiments/external_ knowledge_transformer.py; experiments/ external-knowledge-transformer-v1/runner_ candidate.py	SRC+AGG

实验模块	统一入口；历史源码或冻结证据	复现级别
功能多头与命名通路	research_code/experiments/functional_multihead.py; experiments/public-functional-group-multihead-v1/runner.py; research_code/experiments/named_pathway_tokens.py	SRC+AGG
药物靶点到STRING	research_code/experiments/drug_target_localnet.py; experiments/drug-target-localnet-v1/run_experiment.py	SRC+AGG
菌株基因组与CNV	research_code/experiments/strain_genome_cnv.py; experiments/strain-genome-cnv-v1/run_experiment.py	SRC+AGG
本地双模型机制特征	research_code/experiments/local_llm_mechanism.py; experiments/dual-local-llm-mechanism-v1/run_experiment.py	SRC+AGG
public-only 因果链与 RNA mini	research_code/future_experiments/public_causal_chain/providers.py; research_code/future_experiments/public_rna_lincs_mini/experiment.py; research_code/experiments/public_rna_lincs_mini.py	LIVE
缺失阈值	research_code/experiments/threshold_policy.py; experiments/threshold-control-calibration-v1/RESULTS.md; 仅结构计数仍有效	AGG
新药校准与最终组合路由	reports/complete-research-report-v9/artifact.json; 相关路由源码尚未定位, 缺口登记于 research_code/evidence/registry.json	BLOCKED
LoF 收缩确认	experiments/strain-lof-shrinkage-v1/BLOCKED.json; 因可识别性不足在读取数值前停止	BLOCKED

统一实验入口通过 `research_code/research_cli.py` 调用。当前聚合证据回放核对源文件 SHA-256 与冻结指标, 但不会读取比赛矩阵或伪装成历史模型重训; 完整复现结论与测试记录位于 `research_code/reports/reproducibility-current/`。

5.3 开放与交付

在赛事规则和数据授权允许的范围内，项目计划开放数据字段定义、预处理与缺失掩码逻辑、OOD 划分器、指标实现、基线、模型结构、负对照、分支准入规则、运行环境和聚合报告生成器。比赛原始数据、私有实体映射、样本级或蛋白级私有向量、逐样本预测及许可证不允许分发的外部模型权重不进入公开交付包。

代码仓库在初赛期间保持私有，参赛结束并完成数据授权、许可证和隐私审计后再转为公开。根级 `.gitignore` 与 `PUBLIC_RELEASE_CHECKLIST.md` 规定数据、缓存、临时构建物和本机路径的排除与复核步骤；若私有文件曾进入 Git 历史，仅从工作树删除并不足够，须重写历史或从经过审计的干净快照重新建立公开仓库。

公共数据记录来源、发布日期、许可证、原始文件校验值和派生文件校验值。化合物记录标准 ID、SMILES、InChIKey、来源与映射状态；菌株记录参考基因组、变异文件、版本和映射状态；蛋白知识记录 SGD、GO、Reactome、STRING 等数据库的版本及坐标对齐规则。

5.4 数据与模型合规

比赛数据与公开知识采用独立目录、特征清单和运行配置。获授权训练集用于建模，测试集真值不参与模型拟合、超参数选择或本文结论。外部数据和模型分别核对来源、许可证与再分发条件；所有公开知识特征均保留可追溯的版本与映射记录。

参考文献

- [1] Karr, J. R., Sanghvi, J. C., Macklin, D. N., et al. A whole-cell computational model predicts phenotype from genotype. *Cell*, 150(2):389–401, 2012. doi:10.1016/j.cell.2012.05.044.
- [2] Bunne, C., Roohani, Y., Rosen, Y., et al. How to build the virtual cell with artificial intelligence: Priorities and opportunities. *Cell*, 187(25):7045–7063, 2024. doi:10.1016/j.cell.2024.11.015.
- [3] Qian, L., Dong, Z., and Guo, T. Grow AI virtual cells: three data pillars and closed-loop learning. *Cell Research*, 35:319–321, 2025. doi:10.1038/s41422-025-01101-y.
- [4] Qian, L., Zhou, Z., Zhou, P., et al. Towards the construction of a virtual yeast. *Nature*, 655:59–70, 2026. doi:10.1038/s41586-026-10574-9.
- [5] Viñas Torné, R., Wiatrak, M., Piran, Z., et al. Systema: a framework for evaluating genetic perturbation response prediction beyond systematic variation. *Nature Biotechnology*, 44:1050–1059, 2026; published online 2025. doi:10.1038/s41587-025-02777-8.
- [6] Lotfollahi, M., Wolf, F. A., and Theis, F. J. scGen predicts single-cell perturbation responses. *Nature Methods*, 16:715–721, 2019. doi:10.1038/s41592-019-0494-8.
- [7] Lotfollahi, M., Klimovskaia Susmelj, A., De Donno, C., et al. Predicting cellular responses to complex perturbations in high-throughput screens. *Molecular Systems Biology*, 19(6):e11517, 2023. doi:10.15252/msb.202211517.
- [8] Roohani, Y., Huang, K., and Leskovec, J. Predicting transcriptional outcomes of novel multigene perturbations with GEARS. *Nature Biotechnology*, 42:927–935, 2024. doi:10.1038/s41587-023-01905-6.
- [9] Jolliffe, I. T., and Cadima, J. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065):20150202, 2016. doi:10.1098/rsta.2015.0202.
- [10] Eckart, C., and Young, G. The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3):211–218, 1936. doi:10.1007/BF02288367.
- [11] Hinton, G. E., and Salakhutdinov, R. R. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006. doi:10.1126/science.1127647.
- [12] Kingma, D. P., and Welling, M. Auto-Encoding Variational Bayes. *International Conference on Learning Representations*, 2014. doi:10.48550/arXiv.1312.6114.
- [13] Kipf, T. N., and Welling, M. Semi-Supervised Classification with Graph Convolutional Networks. *International Conference on Learning Representations*, 2017. doi:10.48550/arXiv.1609.02907.

- [14] Hetzel, L., Böhm, S., Kilbertus, N., et al. Predicting cellular responses to novel drug perturbations at a single-cell resolution. *Advances in Neural Information Processing Systems*, 35:26711–26722, 2022. doi:10.48550/arXiv.2204.13545.
- [15] Hochreiter, S., and Schmidhuber, J. Long Short-Term Memory. *Neural Computation*, 9(8):1735–1780, 1997. doi:10.1162/neco.1997.9.8.1735.
- [16] Chen, R. T. Q., Rubanova, Y., Bettencourt, J., and Duvenaud, D. K. Neural Ordinary Differential Equations. *Advances in Neural Information Processing Systems*, 31, 2018. doi:10.48550/arXiv.1806.07366.
- [17] Rubanova, Y., Chen, R. T. Q., and Duvenaud, D. Latent Ordinary Differential Equations for Irregularly-Sampled Time Series. *Advances in Neural Information Processing Systems*, 32:5321–5331, 2019. doi:10.48550/arXiv.1907.03907.
- [18] Giaever, G., Chu, A. M., Ni, L., et al. Functional profiling of the *Saccharomyces cerevisiae* genome. *Nature*, 418:387–391, 2002. doi:10.1038/nature00935.
- [19] Huh, W.-K., Falvo, J. V., Gerke, L. C., et al. Global analysis of protein localization in budding yeast. *Nature*, 425:686–691, 2003. doi:10.1038/nature02026.
- [20] Costanzo, M., VanderSluis, B., Koch, E. N., et al. A global genetic interaction network maps a wiring diagram of cellular function. *Science*, 353(6306):aaf1420, 2016. doi:10.1126/science.aaf1420.
- [21] Peter, J., De Chiara, M., Friedrich, A., et al. Genome evolution across 1,011 *Saccharomyces cerevisiae* isolates. *Nature*, 556:339–344, 2018. doi:10.1038/s41586-018-0030-5.
- [22] Saccharomyces Genome Database. <https://www.yeastgenome.org/>. Accessed 2026-08-09.
- [23] Ashburner, M., Ball, C. A., Blake, J. A., et al. Gene ontology: tool for the unification of biology. *Nature Genetics*, 25:25–29, 2000. doi:10.1038/75556.
- [24] Milacic, M., Beavers, D., Conley, P., et al. The Reactome Pathway Knowledgebase 2024. *Nucleic Acids Research*, 52(D1):D672–D678, 2024. doi:10.1093/nar/gkad1025.
- [25] Morgan, H. L. The generation of a unique machine description for chemical structures—a technique developed at Chemical Abstracts Service. *Journal of Chemical Documentation*, 5(2):107–113, 1965. doi:10.1021/c160017a018.
- [26] Hastings, J., Owen, G., Dekker, A., et al. ChEBI in 2016: Improved services and an expanding collection of metabolites. *Nucleic Acids Research*, 44(D1):D1214–D1219, 2016. doi:10.1093/nar/gkv1031.
- [27] Szklarczyk, D., Kirsch, R., Koutrouli, M., et al. The STRING database in 2023: protein–protein association networks and functional enrichment analyses for any sequenced genome of interest. *Nucleic Acids Research*, 51(D1):D638–D646, 2023. doi:10.1093/nar/gkac1000.

- [28] Szklarczyk, D., Santos, A., von Mering, C., Jensen, L. J., Bork, P., and Kuhn, M. STITCH 5: augmenting protein–chemical interaction networks with tissue and affinity data. *Nucleic Acids Research*, 44(D1):D380–D384, 2016. doi:10.1093/nar/gkv1277.
- [29] Vaswani, A., Shazeer, N., Parmar, N., et al. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 2017. <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>.
- [30] GOAI AI for Research 虚拟细胞赛题说明、训练营回放与《虚拟细胞–解题思路》，2026。