

AI for Research 赛道 | 算法赛初赛方案

虚拟酵母扰动蛋白质组预测：
已知方法迁移的适用边界与机制因果链初探

小米蕉队 | 虚拟细胞方向 | 2026 年 8 月

一、项目概述

1.1 项目名称

虚拟酵母扰动蛋白质组预测：已知方法迁移的适用边界与机制因果链初探。

1.2 参赛方向

GOAI AI for Research 算法赛——虚拟细胞方向。研究对象是酿酒酵母在药物、菌株、培养基、温度和时间条件下的扰动蛋白质组响应。

1.3 方案概述

扰动预测和虚拟细胞方向已经有不少方法，但这些方法大多在人类单细胞转录组的大规模数据上提出和验证。本项目面对的是酿酒酵母蛋白质组，独立扰动实体较少，数据规模和输出形式也与常见的单细胞任务明显不同。2025 年 Virtual Cell Challenge 的赛后总结以及 Systema 对相关方法的评估还提示了一个实际问题：不少纯深度模型并没有超过“预测平均响应”这样的朴素基线，数据越少，过拟合和错误归因的风险越大。[\[2,15\]](#)

基于这些情况，我们先把任务拆成三个可以直接检验的问题：第一，数据中是否存在可重复的药物扰动。第二，药物身份、菌株差异和实验条件是否对应稳定的蛋白变化。第三，现有数据规律和外部知识能否支持对未见药物、菌株或时间条件的 OOD 外推。对于未见药物，我们重点考察分子结构、相似药物、公共机制知识和语言模型提取的药物信息。对于未见菌株和新时间条件，则重点利用菌株特征、其他菌株中的同药响应和已有时间轨迹。

接下来，我们先统一数据处理口径，按照完整药物或菌株划分训练集和验证集，并通过打乱药物身份、分子结构或机制标签等对照实验排查数据泄漏和虚假增益，再将已有方法迁移到酵母蛋白质组任务中。迁移和改造的路线包括 Metadata Ridge、低秩模型与 MLP，基于 Morgan 指纹和 CPA/chemCPA 思路的分子结构模型，时间与菌株残差专家，以及知识网络、本地 Qwen/Gemma 和 TxGemma 表示。我们重点检验这些原本主要用于大规模单细胞转录组或其他扰动任务的方法，在小样本、高维蛋白质组数据上是否仍然有效。

在这些迁移实验的基础上，我们针对当前数据设计了几项新探索：用多层去中心区分基础蛋白谱、共享扰动和药物特异响应，让语言模型只处理药物侧公开知识，构建可检验的“靶点—通路—蛋白模块”因果链，并将共享响应轴与药物特异残差分开预测。我们还设计了 MiJiaoPredict 证据门控框架，以 Metadata Ridge 提供稳定核心，根据输入条件选择专家。初赛先使用规则明确、可审计的手工门控。复赛将优先继续验证智能体因果链，让智能体检索公开资料、提出带来源的机制假设，并判断何时调用、组合或拒绝专家。框架仍保留适用范围检查和基础预测回退，也为时间、菌株、分子结构、知识和语言模型等后续专家保留统一接口。

二、科学问题理解

2.1 研究背景、对象与待验证问题

虚拟细胞背景与本题范围

虚拟细胞的基本目标，是根据细胞当前状态、外部干预和实验环境，预测干预后的分子状态，从而在进入湿实验前筛选更值得验证的条件。现有扰动预测方法大多在人类单细胞转录组和大规模筛选数据上开发，常见任务是根据基因敲除或药物信息预测转录变化。[\[1,4-5\]](#)

本题的研究对象有所不同。它预测的是酿酒酵母蛋白质组，而不是单细胞转录组。药物是主要扰动

变量，菌株、培养基、温度和时间共同定义药物作用时的实验条件。因此，本题关注的是不同实验条件下，药物扰动与蛋白丰度状态之间的对应关系。

研究对象、输入输出与数据合同

比赛任务要求由实验条件预测数千个蛋白的连续丰度。输入包括药物、菌株、培养基、温度和时间，source 与 instrument 是观测环境信息，plate 仅作为泄漏与批次审计字段。输出不是一个类别，而是高维、缺失不齐且基础丰度跨度很大的蛋白向量。最终提交文件严格采用赛事最新模板规定的蛋白列及排列顺序。程序通过每个样本唯一的 sample_ID 将预测结果填入对应位置，因此即使输入 CSV 的行顺序发生变化，也不会把不同样本的预测结果错配。

表 1：核心数据规模与工程口径

对象	规模/规则	在方案中的作用
TRAIN 样本	5,920 行	模型训练与内部验证
原始数据中的蛋白	5,243 个	构成最终完整输出
非对照药物	标准化后 37 种药物	将盐型和别名归并为同一药物，验证时完整留出一种药物
生物实验条件	96 种组合	菌株 × 培养基 × 温度 × 时间
用于模型拟合的蛋白	缺失率严格小于 80%，共 4,422 个	由模型学习和预测
安全补全的蛋白	不满足拟合条件，共 821 个	使用训练集均值或模板规则补齐最终提交

三个待验证问题

为了把比赛任务拆成可以逐步检验的部分，我们提出以下三个研究问题。它们是本项目的分析框架，不是预先成立的科学结论。每个问题都对应具体实验和反例，验证失败同样会被保留为结果。

表 2：三个待验证问题及其验证路径

问题	需要解决的关键问题	主要验证
Q1 数据中是否存在真实药物扰动？	区分真实扰动与稳定蛋白均值、噪声或实验批次造成的表面相关	直接比较实测蛋白响应，检查同一种药在不同样本间是否比不同药物更相似
Q2 药物身份是否对应特定蛋白变化？	区分药物特异变化、所有药物共有的响应与实验批次影响	减去基础蛋白水平和共同响应，分析剩余的药物特异变化，并比较正确药物身份与打乱后的药物身份
Q3 现有数据规律和外部知识能否支持 OOD 外推？	未见药物、未见菌株和新时间条件能够使用的信息不同，需要区分真正的新药外推与利用已有实验轨迹的场景适配	分别留出完整药物、菌株或时间条件。新药实验比较分子结构、知识网络和语言模型，菌株与时间实验比较菌株特征、同药响应和已有轨迹

2.2 科学意义

酿酒酵母是构建虚拟细胞的合适起点。它生长快、培养成本相对低，培养基、温度、时间和遗传背景容易控制，也便于重复实验和高通量扰动。酵母的遗传学、代谢和蛋白质组研究基础较完整，许多基因和通路已有可查询的功能信息。因此，模型提出的药物响应或机制假设可以较快回到真实实验中检验，而不是长期停留在计算结果上。[1]

更长远的意义是把预测模型接入自动化实验闭环。《Towards the construction of a virtual yeast》给出的 virtual yeast AI agent 路线，正是让模型整合多模态数据和机制知识，提出下一轮实验，再由自动化平台执行培养、扰动和测量，并用新数据继续修正模型。酵母培养稳定、操作流程成熟，适合机器人连续完成配液、接种、培养、加药、采样和检测。因而，本项目不仅是在比较预测算法，也是在为后续“模型提出候选—机器人执行实验—结果反馈模型”的虚拟酵母系统建立一个可运行的药物扰动预测模块。[1]

三、技术方案与预期方法路线

3.1 技术方案

数据处理、估计目标与评价指标

比赛数据中，每一行代表一个实验样本，每一列代表一种蛋白，数值表示该样本中测得的蛋白丰度。我们先检查哪些数值缺失或无法使用，再按照训练数据中的缺失比例决定哪些蛋白可以由模型学习。缺失率严格小于 80% 的 4,422 个蛋白进入主要拟合。其余 821 个蛋白仍保留在最终输出中，但采用训练均值或提交模板规定的安全补全方式，不把它们误当成已经学会的结果。

评价时同时看两个层面：第一类指标比较模型预测的最终蛋白丰度与实测丰度，用来判断整体蛋白状态是否预测准确，但它容易受到稳定基础蛋白谱的影响。第二类指标评价药物引起的相对变化。为了分别判断药物相对对照产生的变化，以及该药物是否表现出超过同一实验条件常见反应的特异变化，程序分为两个步骤：首先，对每个药物样本查找数据来源、菌株、培养基、温度、时间、仪器和培养板都相同的对照样本，用药物处理后的蛋白丰度减去这些对照的平均蛋白丰度。其次，在完整留出一种药物的验证中，只使用其余训练药物，计算上述实验条件完全相同时药物相对对照变化的平均值，再从待评价药物的相对变化中减去这个平均值。

数据没有给出每种药物应使用 DMSO 还是 Water 作为唯一溶剂对照，因此我们作出一个明确假设：在数据来源、菌株、培养基、温度、时间、仪器和培养板完全一致时，DMSO 与 Water 都可以作为候选溶剂对照。程序将该条件下能够找到的 DMSO 和 Water 对照合并求平均，再计算药物相对对照的变化。这个假设使现有数据可以用于比较模型是否捕捉到药物变化，同时也带来局限：如果某种药物实际上只应对应其中一种溶剂，合并对照会引入偏差。因此，第四章实验结果只把它作为“合并溶剂对照下的内部分析”报告，不与能够明确匹配唯一溶剂对照的结果混在一起。验证某一种药物时，我们会先把这种药物的全部实验结果从训练集中拿掉，模拟它是一个新药。模型训练、平均背景、标准化和低秩表示都只根据其他药物计算，保证最后的分数反映模型对未见药物的预测能力，而不是提前利用了该药物自己的结果。

表 3: 本文使用的六类评价指标

指标/目标	回答的问题	主要风险
最终蛋白丰度的 PCC / R ²	整体蛋白轮廓是否准确	容易被稳定的基础蛋白谱抬高
相对同条件对照的变化	药物处理后相对对照升高或降低了多少	依赖对照是否存在以及匹配是否合理
相对完全相同实验条件平均值的 变化	模型是否预测了超出该条件常见反应的部分	平均值必须只用其余训练药物计算
共享响应之外的药物特异变化	模型是否区分了不同药物的响应模式	对小样本、缺失和测量噪声更敏感
均方根误差与预测方差	预测幅度是否合理，是否过度缩向均值	只看相关系数可能奖励过度平滑
高响应蛋白的命中率与方向	大幅变化的蛋白是否找对，上升下降是否一致	判断阈值和蛋白范围需要提前确定

这六类指标会在第四章按实验目的分别使用。问题一主要看同药复现、异药对照、AUC 和最相似响应能否识别同一种药。问题二主要看相对对照变化、去掉共同响应后的药物特异变化，以及药物信息错配后增益是否消失。最终蛋白丰度、误差、预测幅度和高响应蛋白方向则用于检查模型是否只是得到较高相关，却没有预测对具体变化。

验证设计：防止分数虚高

不同的数据划分方式，实际回答的是不同层面的问题。随机拆分样本看似简单，但容易把同一药物或菌株的重复实验拆散到训练和验证两边，这样测出来的分数往往过于乐观。因此，我们改按药物、菌株或实验条件整体留出。需要特别指出的是，只有“完整留出一种药物”这一设置，才真正测试模型面对全新药物时的表现。留出菌株、测试新组合，或是利用已有条件下的早期数据，它们解决的是其他类型的问题，不能等同于对新药的预测。所以我们做出以下定义：

- 完整留出药物（whole-drug）：将同一种标准化药物的全部样本从训练集中删除，再预测该药物。这是本项目检验未见药物外推的主要方法。
- 完整留出菌株（whole-strain）：将一个菌株的全部样本留作验证，但模型仍可能使用同一种已见药物在其他菌株中的响应。
- 留出实验条件组合（whole-Kbio）：药物和菌株都曾在训练中出现，只是它们的某种条件组合没有出现。它检验组合泛化，不能替代未见药物验证。
- 时间留出与早期状态预测（rolling-time / prefix）：按时间顺序预测后续状态，其中 prefix 模型会读取同一查询条件的早期真实蛋白状态，因此属于有前缀信息的预测。
- 置信区间与置换以药物、菌株或机制簇为单位，不把数千蛋白坐标当作独立生物重复。

这里还有一个容易被忽略的点：验证某一种药物时，不能只把该药的样本从模型训练中删除。数据均值、标准化、低秩表示和参数选择也要重新在其余药物上完成。需要调参数时，再在这些训练药物内部划分训练组和验证组。比较不同模型时，只在双方都有实测值的同一批蛋白上评分。

现有方法的迁移实验

本项目先建立一组由简单到复杂的对照实验。这样做不是为了罗列模型，而是为了回答两个具体问题：第一，常见扰动预测方法迁移到小样本、高维酵母蛋白质组后是否仍然有效。第二，性能变化究竟来自模型本身，还是来自额外信息、数据覆盖或任务难度的变化。每类方法都按它要回答的问题选择验证划分方式，并与相同输入条件下表现最稳的简单模型比较。

表 4：现有方法的迁移实验及其验证目的

方法组	迁移和改造方式	为什么要做
均值与 Metadata Ridge	用训练集均值、实验条件和药物身份建立完整预测，并以岭回归控制共线性	先确认稳定基础谱和简单条件效应能够解释多少结果，为复杂模型提供诚实基线。岭回归适合独立药物少、特征相关而输出维度高的情况。[16]
低秩模型与 MLP	在相同条件输入下比较直接 MLP、低秩 MLP 和加性分解 MLP，并以 Metadata Ridge 作为线性参照	分别检验非线性映射、低维响应表示和显式条件分解是否比线性模型更适合当前数据。[17]
分子结构模型	比较 Morgan 近邻迁移、CPA 风格的结构与条件相加模型、结构与实验条件交互，以及冻结 chemCPA 药物表示	结构是完全未见药物仍可获得的信息。这组实验检验结构相似是否能支持新药外推，而不是记住药名。[3-5]
时间与菌株专家	利用同一已见药物在其他菌株中的响应，或同一实验条件在其他时间点的响应，预测新的菌株或时间点	这类模型检验已有实验记忆能否在限定场景中迁移，并明确它与完全未见药物预测的区别。
知识网络与公共机制	由 STITCH、STRING、GO、Reactome 和公开菌株资源构造靶点、通路、蛋白模块和菌株负担特征	检验公共生物知识能否在结构之外提供可解释的迁移信息，并用错误对应关系排查仅由覆盖度或网络中心性造成的假增益。[6-10]
Qwen、Gemma 与 TxGemma	用本地语言模型生成药物机制表示、相似药物检索特征和模型间共识，并测试 TxGemma 冻结表示	检验预训练模型中的药物和机制知识能否迁移到酵母蛋白响应，而不是直接把语言模型当作数值预测器。[11,18,19]
多模型组合与条件路由	比较固定组合、按条件学习模型权重和按照场景规则选择模型	检验不同预测模型是否各自在某些条件下更可靠，以及根据查询条件选择模型能否超过始终使用同一个模型。[20]

按照模型使用的信息，这些实验分成三类，共同回答问题三，也就是现有数据规律和外部知识能否帮助模型从已见条件迁移到未见药物、菌株或时间条件。第一类只使用赛事数据中的实验条件，包括均值模型、Metadata Ridge、低秩模型和 MLP。均值模型是最朴素的参照，Metadata Ridge 是经过验证后表现稳定的简单模型，也是 MiJiaoPredict 生成完整预测的基础模型和安全兜底。低秩模型与 MLP 是对 Ridge 的升级尝试，用来判断输出压缩或非线性网络能否进一步改善结果。第二类加入药物结构和机制信息，包括分子结构模型、知识网络和语言模型，主要用于预测完全未见的药物。第三类使用查询场景中额外可获得的实验信息，包括其他菌株、其他时间点、实测对照和早期状态，用于预测未见菌株

或新时间条件。三类方法会分别与使用相同信息的简单模型比较，判断新增信息或模型改造带来了多少改善。

- 1. 统计基线与非线性模型：**均值模型先回答最基本的问题：如果完全不区分药物，只预测训练集中常见的蛋白轮廓，能够得到多高的表面分数。Metadata Ridge 在此基础上加入菌株、培养基、温度、时间、药物和观测来源等条件，用正则化线性模型估计每项条件的贡献。随后再加入低秩响应和 MLP，才能公平判断非线性是否必要。如果 MLP 只比均值强、却没有超过相同输入的 Ridge，那么提高主要来自条件信息，而不是深度网络本身。
- 2. 药物结构与完全未见药物：**Morgan 指纹和理化描述符提供的是药物本身的信息，即使该药没有蛋白结果也可以计算。我们没有完整复现 CPA 或 chemCPA，而是做了适合本题的小容量改造。程序分别编码药物结构，以及菌株、培养基、温度和时间等实验条件，再把蛋白响应压缩成 32 个低维坐标。CPA 风格模型用 Ridge 分别计算药物结构和实验条件对应的变化，再把两部分相加。另一个模型进一步加入药物结构与实验条件的交互，用来表示同一种结构在不同条件下可能产生不同影响。我们还把冻结的 chemCPA 药物表示接入相同预测流程，与 RDKit、外部 PCA 和随机表示比较。最后将低维坐标还原为蛋白预测，并用完整药物留出、结构错配和随机指纹检验改善是否真的来自正确的分子信息。
- 3. 实验记忆与场景模型：**时间和菌株模型利用的是训练集中已经实测的邻近响应。例如，在预测新菌株时，可以参考同一药物在其他菌株中的变化。在预测新时间点时，可以参考同一实验条件的其他时间点。这类信息通常比仅看元数据更直接，因此值得单独建模，但它们解决的是“已有药物或已有实验轨迹如何迁移”，不是完全没有实测响应的新药预测。实测对照和早期蛋白状态也按同样原则作为条件模型，而不并入默认零样本输入。
- 4. 公共知识与预训练表示：**我们把公开数据库中的关系接成“药物、靶点、蛋白相互作用和通路”网络。STITCH 提供药物与靶点的关系，STRING 提供蛋白之间的相互作用，GO 和 Reactome 提供蛋白功能与通路。由此得到的特征可以说明一个药物连接了哪些靶点、邻近蛋白和通路，也能追溯两个药物为什么被认为相似。另一条路线使用预训练模型生成药物特征：Qwen 和 Gemma 产生 49 维机制特征，TxGemma 从固定药名提示中提取 2,304 维隐藏向量。这些向量是药物的数值表示，不是最终蛋白预测。当前只有 37 种独立药物，使用简单预测模型可以减少过拟合。为了判断这些药物特征本身是否有用，我们使用相同的 Ridge 或低秩模型，分别输入正确的药物特征和随机错配的药物特征。两组实验保持数据划分、模型结构和参数选择方式一致，只改变药物与特征的对应关系。如果正确特征稳定优于错配特征，才能说明增益来自药物信息，而不是预测模型本身的差异。验证时完整留出一种药物，并进一步测试机制方向反转和错误网络关系，检查模型是否真正使用了正确知识。
- 5. 按条件选择模型：**不同实验提示，某些模型可能只在特定输入齐全时有优势。固定平均会让无关或不稳定的模型影响所有样本，因此我们同时测试静态模型组合、学习型门控和规则路由。这里最重要的不是“模型越多越好”，而是门控在看不到查询结果的前提下，能否根据可用信息判断哪个模型值得使用。这也为后面的 MiJiaoPredict 总模型提供直接依据。

本项目针对数据特点设计的实验

- 1. 多层去中心与共享响应诊断：**蛋白质组中稳定的基础蛋白谱很强，直接计算相关系数容易把“蛋白本来就高或低”误当成药物效应。我们依次区分基础蛋白谱、相同实验条件下的共享响应和共享响应之外的药物特异变化，并在训练折内重新计算中心、尺度和低秩基。药物相似网络还单独扣除“某个药物普遍接近多数药物”的节点效应，避免把典型药物误认为特异相似药物。这里的共享响应和药物特异变化，就是下文问题二与“创新探索二”中的“共享响应轴与药物特异残差”。

2. **药物侧公开知识因果链（创新探索）**：我们让语言模型只读取药物名称、靶点和公开机制资料，先提出“靶点、通路、蛋白模块”的有向假设，再由训练数据中的 Ridge 或低秩模型学习这些模块对应的数值变化。这样可以检验机制假设是否真的提供增量，也避免语言模型提前看到被留出药物的蛋白结果。公开磷酸化蛋白组被作为药物作用与总蛋白变化之间的候选中间表示，用于检验这条链路的局部可行性。

3. **共享响应轴与药物特异残差**：我们进一步把药物响应写成

$$\Delta Y(d, c) = \mu(c) + a(d)G + Q(d, c),$$

其中 $\mu(c)$ 表示实验条件下的平均响应， G 表示由训练药物定义的共享统计响应轴， $a(d)$ 表示某种药物推动该轴的强度， $Q(d, c)$ 表示共享轴之外的药物特异残差。该设计用于判断一个模型的改善究竟来自“预测总体扰动强弱”，还是确实预测了不同药物之间的差异。后续可先按照 GO 功能、通路或 STRING 网络关系，把功能相关的蛋白分成若干组，预测每组蛋白的整体变化，再逐步细化到单个蛋白。分组规则必须在查看被留出药物的结果之前确定，以免事后挑选恰好变化较大的蛋白。

4. **证据门控的模型组合**：迁移实验和上述新方法最终不是简单平均。我们先让每个候选在对应问题中独立接受验证划分和负对照检验，再记录它在哪些输入条件下有效。通过验证的能力进入总模型，在未覆盖、没有稳定增量或所需信息缺失时，不强行使用特殊模型。

3.2 预期方法路线

从候选实验到总模型

整体路线见图 1。均值和 Metadata Ridge 先生成基础预测，其他候选分别完成实验和对照检验，确认有效后再接入 MiJiaoPredict，最后按官方样本和蛋白顺序生成提交文件。

预期总模型：MiJiaoPredict 手工证据门控

在前述实验基础上，本项目将最终总预测器命名为 MiJiaoPredict。它不是一个单一神经网络，也不是把所有模型固定平均，而是一个手工证据门控的多专家系统。Metadata Ridge 作为 shared core，先对每个查询生成完整预测。然后，路由器根据药物和菌株是否在训练中出现、是否属于时间外推、是否有实测对照或早期状态、分子和机制特征是否可用，以及相应专家是否已经在该范围内通过验证，再决定是否使用专家修正。




图 1: MiJiaoPredict 的五个环节及回退关系。数据合同约定全部模型，专家未通过证据门控时保留 shared core 预测。

MiJiaoPredict 的核心原则可以写成：

$$\hat{Y}_{\text{MiJiao}}(q) = \begin{cases} \hat{Y}_{\text{Ridge}}(q) + \hat{R}_e(q), & \text{残差专家适用且已通过验证,} \\ \hat{Y}_e(q), & \text{替换专家适用且已通过验证,} \\ \hat{Y}_{\text{Ridge}}(q), & \text{其他情况.} \end{cases}$$

这里的“回到 Ridge”表示：如果某个专家不适用于当前样本，或者没有在相应验证中稳定超过 Ridge，MiJiaoPredict 就不采用该专家，继续使用 Ridge 的预测。这样可以避免表现较差的专家拉低结果，同时保证每个样本都有完整、有限且坐标一致的输出。当前版本先采用容易审计的手工规则。复赛将先完善智能体因果链和资料检索流程，再根据专家验证结果探索动态路由，同时保留相同的安全回退和路由记录。

3.3 数据来源与工具

数据与外部资源

核心数值来自赛事授权 TRAIN。其中的实验条件和蛋白丰度用于模型训练和内部验证。外部资源只提供分子结构、药物机制或菌株基因组特征，不提供比赛蛋白结果。STITCH 提供药物与靶点的关系，STRING 提供蛋白之间的互作关系，SGD 提供酵母基因注释，GO 和 Reactome 提供功能类别和通路信息。2018 年发表的一项大规模酵母基因组研究汇总了 1,011 株酿酒酵母的基因组差异，包括功能缺失、移码、基因存在或缺失、拷贝数变化和 SNP 距离。本项目用这些信息描述不同菌株的遗传背景。各类方法具体使用的数据与外部资源见表 5。[3,6–12]

表 5: 各类方法使用的数据和外部资源

方法	使用的数据和资源	在模型中的作用
均值、Metadata Ridge、低秩与 MLP	TRAIN 中的实验条件和蛋白丰度	生成基础预测，比较线性、低秩和非线性模型
Morgan 与 CPA/chemCPA 风格模型	TRAIN、PubChem/RDKit 分子结构、冻结 chemCPA 药物表示	为完全未见药物提供结构特征
时间、菌株和前缀专家	TRAIN 中其他菌株、时间点、实测对照或早期蛋白状态	在这些信息可用时修正基础预测
菌株基因组模型	TRAIN、2018 年发布的 1,011 株酵母基因组资源	构造菌株突变、拷贝数和通路负担特征
知识网络与因果链	TRAIN、STITCH、STRING、SGD、GO、Reactome 和公开磷酸化蛋白组	构建靶点、通路和蛋白模块特征
Qwen、Gemma 与 TxGemma	TRAIN、本地或冻结的预训练模型	生成药物数值表示，再由 Ridge 或低秩模型转换为蛋白预测
MiJiaoPredict	查询条件、候选模型预测和已验证的适用范围	选择专家，保留 Ridge 回退并生成提交结果

各类方法使用的主要工具

不同方法所用的主要工具和程序库见表 6。安装方式、运行命令、模型文件和各实验的程序入口统一放在第五章第 5.1 节。

表 6: 各类方法使用的主要工具和程序库

方法	主要工具或程序库	用途
数据整理与指标计算	Python、NumPy、pandas	样本对齐、缺失处理、数值计算和结果汇总
Metadata Ridge 与低秩模型	NumPy、pandas、scikit-learn	Ridge 回归、降维、整药留出验证和基础预测
MLP 与学习型路由	PyTorch	训练 MLP、BasisMLP 和 GRPO 路由实验
分子结构模型	RDKit、PubChem 程序接口	标准化分子结构，计算 Morgan 指纹和理化特征
知识网络与因果链	Python、pandas、STITCH/STRING/GO/Reactome 数据文件	连接药物、靶点、通路和蛋白模块
本地 Qwen/Gemma	Ollama、Python	生成药物侧机制特征、相似药物信息和候选因果链
TxGemma	PyTorch、Transformers	提取冻结的药物 embedding，再由 Ridge 或低秩模型预测蛋白变化
MiJiaoPredict 与测试	Python、uv、unittest	调用基础模型和专家，记录路由结果并运行合成测试

四、阶段性实验结果或可行性验证

4.1 阶段性实验或可行性验证

统一实验合同

我们根据要检验的对象划分验证集：预测新药时完整留出该药，预测新菌株时完整留出该菌株，预测新组合时留出对应的药物与菌株组合。因此，这些实验不合并成一个总分，而是在各自的任务中或使用相同信息的简单模型比较。

以新药预测实验为例，我们每次拿出一种药物作为验证对象，其余药物用于训练。需要选择参数时，

只在其余药物中再划分训练组和验证组，被拿出的药物始终不参与训练或参数选择。比较两个模型时，只评价两者都有实测值的同一批蛋白，并且使用同一种计算方法。最后，每个被留出的药物或菌株先得到一个误差分数，再把这些分数相加后除以药物或菌株的数量。这样，样本多的对象和样本少的对象对最终结果的影响相同。

表 7：判断模型改进是否可信的检查项

检查什么	怎么检查	想排除的假象
是否超过简单方法	与均值预测和 Metadata Ridge 比较	只是复现稳定的基础蛋白谱
改进是否来自该药物自己的结构或机制资料	保持预测方法不变，把药物和结构或机制资料随机错配后重新运行	使用别的药物资料也能得到同样改善
是否预测对了上升和下降	与全部预测上升、全部预测下降或反转机制方向的结果比较	只是利用上升和下降数量不均
是否只学到所有药物共有的反应	去掉训练药物的平均反应后再次评价	只会预测总体扰动强弱
是否对多数药物或菌株有效	分别查看每个留出对象的结果，并通过重复抽样观察波动	只由少数对象带来改善
是否保持合理的误差和变化幅度	同时检查绝对误差、预测变化大小以及变化最明显蛋白的方向	靠过度缩小预测或只命中常见蛋白
是否有足够数据进行评价	检查每次训练和验证中有实测值的蛋白数量	数据不足却仍然强行报告分数

候选模型不会因为某一个相关系数略高就进入 MiJiaoPredict。只有当它在主要评价指标上明显超过使用相同信息的简单模型，对多数被留出的药物或菌株都有改善，最差情况没有明显变坏，并且优于随机错配药物信息的对照时，才会被采用。数据覆盖不足或所需资源缺失时，结果记为“无法评价”，不视为模型性能为负。

4.2 当前结果

问题一：数据中是否存在可重复的药物扰动？

先做一个不区分药物和实验条件的均值预测。对每个蛋白 (p)，只用训练集中有实测值的样本计算平均丰度：

$$\mu_p = \frac{1}{N_p} \sum_{i \in \text{TRAIN}, Y_{i,p} \text{ available}} Y_{i,p}, \quad \hat{Y}_{s,p}^{\text{mean}} = \mu_p.$$

也就是说，无论查询样本是什么药物和条件，都输出同一条平均蛋白谱。这里同时计算两个指标。“总体 PCC”先把所有有实测值的样本和蛋白组合放在一起，再计算预测值与实测值的 Pearson 相关：

$$\text{PCC}_{\text{all}} = \frac{\sum_{(s,p) \in \Omega} (Y_{s,p} - \bar{Y})(\hat{Y}_{s,p} - \bar{\hat{Y}})}{\sqrt{\sum_{(s,p) \in \Omega} (Y_{s,p} - \bar{Y})^2} \sqrt{\sum_{(s,p) \in \Omega} (\hat{Y}_{s,p} - \bar{\hat{Y}})^2}}.$$

其中， Ω 是实测值存在的样本和蛋白组合， $\bar{Y}$ 和 $\bar{\hat{Y}}$ 分别是这些位置上的实测均值和预测均值。这个指标同时包含蛋白之间的丰度差异和实验条件之间的差异。

“逐蛋白 R^2 ”则对每个蛋白单独计算，检查模型能否预测该蛋白在不同样本中的高低变化：

$$R_p^2 = 1 - \frac{\sum_{s \in \Omega_p} (Y_{s,p} - \hat{Y}_{s,p})^2}{\sum_{s \in \Omega_p} (Y_{s,p} - \bar{Y}_p)^2}, \quad \overline{R^2} = \frac{1}{|\mathcal{P}|} \sum_{p \in \mathcal{P}} R_p^2.$$

$\bar{Y}_p$ 是该蛋白在被评价样本中的平均实测值， $\mathcal{P}$ 是可以计算 R^2 的蛋白集合。 $R_p^2 = 1$ 表示该蛋白被完全预测， $R_p^2 = 0$ 表示预测与直接使用该蛋白在评价样本中的平均值相当，负值表示还不如这个平均值。因此，如果均值预测的总体 PCC 很高，但逐蛋白 R^2 很低，就说明高相关主要来自“哪些蛋白通常较高，哪些通常较低”这条稳定基础轮廓，而不是模型跟随药物和实验条件预测了单个蛋白的变化。

第二个检查直接比较同药和异药的扰动响应。程序先把同一药物、菌株、培养基、温度和时间下的技术重复合并，再对每个实验条件 (c) 计算药物相对匹配对照的变化，并减去该条件下其他药物的常见变化：

$$\Delta Y_{d,c,p} = Y_{d,c,p} - \bar{Y}_{\text{control}(c),p}, \quad Z_{d,c,p} = \Delta Y_{d,c,p} - \overline{\Delta Y}_{d' \neq d, c, p}.$$

然后，程序只根据菌株、培养基、温度和时间等元数据，将 96 种生物实验条件平衡分成 A、B 两组，分组时不查看蛋白结果。每种药物在两组中分别得到一条平均残差蛋白谱：

$$S_{d,p}^{(h)} = \text{mean}_{c \in C_h} Z_{d,c,p}, \quad h \in \{A, B\}, \quad r_{d,d'} = \text{corr}_p(S_{d,p}^{(A)}, S_{d',p}^{(B)}).$$

因此，每种药都有两条蛋白谱。 $S_{d,p}^{(A)}$ 是药物 d 在 A 组条件中的平均残差蛋白谱。 $S_{d,p}^{(B)}$ 是同一种药在 B 组条件中的平均残差蛋白谱。

矩阵 (r) 的对角线是同一种药在两组条件中的相关，非对角线是不同药物之间的相关。如果药物标签与蛋白变化无关，两类相关应当接近，最相似响应来自同药的比例也应接近随机水平。反之，同药相关持续高于异药，才支持数据中存在与药物身份相关、可跨实验条件重复的扰动信号。这项检查支持“有可重复信号”，但不等于证明每个蛋白的变化都可预测。相应函数和文件统一列在第五章表 11。[2]

为了把两类相关的区分程度写成一个数，定义同药分数集合和异药分数集合：

$$\mathcal{R}_{\text{same}} = \{r_{d,d} : d = 1, \dots, 37\}, \quad \mathcal{R}_{\text{diff}} = \{r_{d,d'} : d \neq d'\}.$$

前者包含 37 个正确同药配对，后者包含 $37 \times 36 = 1,332$ 个错误异药配对。两组分数的中位数为

$$\tilde{r}_{\text{same}} = \text{median}_d r_{d,d} = 0.378, \quad \tilde{r}_{\text{diff}} = \text{median}_{d \neq d'} r_{d,d'} = 0.044.$$

AUC 直接计算所有“一个同药分数和一个异药分数”的两两比较：

$$\text{AUC} = \frac{1}{|\mathcal{R}_{\text{same}}| |\mathcal{R}_{\text{diff}}|} \sum_{a \in \mathcal{R}_{\text{same}}} \sum_{b \in \mathcal{R}_{\text{diff}}} \left[\mathbf{1}(a > b) + \frac{1}{2} \mathbf{1}(a = b) \right].$$

式中的 $\mathbf{1}(\cdot)$ 表示条件成立时记 1，不成立时记 0。因此，AUC 也可以直接解释为：从两个经验分数集合中各抽一个分数，同药分数更高的比例，并列时计一半。药物标签完全无信息时，AUC 应接近 0.5。

对 A 组中每种药 d ，在 B 组的 37 个候选中选出相关最高的药物 d' ，并检查它是否为同一种药：

$$\text{Top1}_{A \rightarrow B} = \frac{1}{37} \sum_{d=1}^{37} \mathbf{1}\left(d = \arg \max_{d'} r_{d,d'}\right), \quad \text{Top1} = \frac{\text{Top1}_{A \rightarrow B} + \text{Top1}_{B \rightarrow A}}{2}.$$

公式中的 $\arg \max$ 表示选出相关最高的候选。每次找对记 1，否则记 0，求和后除以 37 得到命中率，不是相关系数的平均。程序再计算 B 到 A 的命中率，并取两个方向的平均。并列第一时平分该次命中。随机命中率为 $1/37 = 2.7\%$ 。

这里的 0.9411 来自早期固定验证集 (validation) 诊断，不是 TRAIN 内部留出结果。早期分析用 TRAIN 中每个蛋白的均值预测固定验证集中的 3,038 条样本，得到总体 PCC 0.9411。由于 R^2 的 0 分参照是固定验证集中该蛋白自身的均值，TRAIN 与固定验证集之间的均值偏移使逐蛋白平均 R^2 为 -0.0413。这个诊断只用于说明稳定基础蛋白谱会抬高总体相关，不参与当前仅使用 TRAIN 的模型选择。AUC 为 0.939，即同药分数在 93.9% 的两两比较中高于异药分数。top-1 为 61.2%，即用一组条件下的药物蛋白谱去检索另一组中的 37 种候选药物时，最相似者平均有 61.2% 是正确的同一种药，明显高于随机检索的 2.7%。



图 2: 同药复现检验的计算过程。A、B 两组实验条件分别形成 37 条药物残差蛋白谱，相关矩阵的对角线是正确同药配对，非对角线是错误异药配对。

这组结果说明，训练数据中确实存在能够跨实验条件重复出现的药物相关蛋白变化。理由不是总体 PCC 很高，而是在先去掉匹配对照和同条件共同变化后，正确同药配对仍明显高于错误异药配对。如果数据只剩噪声，或只剩所有样本共有的稳定蛋白轮廓，AUC 应接近 0.5，top-1 应接近 2.7%，而不会达到 0.939 和 61.2%。

这个结论只证明“存在可复现的药物信号”，不代表每种药物的每个蛋白都能被精确预测。而且独立非对照药物只有 37 种，这意味着复杂模型的训练样本和药物级验证次数都很有限。因此，后续实验一方面要检查最终蛋白丰度是否准确，另一方面也要单独检查模型是否预测了药物相对对照以及超出同条件共同变化的部分，不能只看总体相关系数。

问题二：药物身份是否对应特定蛋白变化？

问题一证明了同一种药物的总体响应更相似，但还不能说明模型找到了该药特有的蛋白变化。为此，分析分三步进行。第一步计算药物相对同条件对照的变化：

$$\Delta Y(d, c) = Y_{\text{drug}}(d, c) - \bar{Y}_{\text{control}}(c).$$

其中 d 表示药物， c 表示数据来源、菌株、培养基、温度、时间、仪器和培养板完全相同的实验条件。第二步只使用其他训练药物，减去该实验条件下常见的平均变化：

$$R(d, c) = \Delta Y(d, c) - \bar{\Delta Y}_{\text{other drugs}}(c).$$

第三步再使用前文所述的“共享响应轴与药物特异残差”进行分解。共享响应轴概括多种药物都会引起的主要变化方向，药物特异残差则保留该药物偏离这一共享方向的部分：

$$R(d, c) = a(d)G + Q(d, c).$$

G 是由其他训练药物得到的共享响应轴， $a(d)$ 表示该药物沿共享轴变化的强度， $Q(d, c)$ 才是本项目希望进一步预测的药物特异残差。

还需排除“共用对照”造成的假相似。这项诊断使用主分析中的 23 种同一数据来源且具有可用分子结构的药物。23 种药物任取两种，共形成

$$\binom{23}{2} = \frac{23 \times 22}{2} = 253$$

个不重复药物对。若一对药物 A、B 都减去同一组 Water 的中位蛋白谱 W ， $A - W$ 与 $B - W$ 会共同带入 W 的测量误差，即使 A、B 本身不相似，相关也可能升高。对每个药物对计算一次蛋白维度上的相关，再对 253 个相关系数取中位数，结果为 0.405。

为判断 0.405 是否来自共用 Water，在至少含两个 Water 重复的区块内，将重复样本分为互不重叠的 W_1 和 W_2 ，再比较 $A - W_1$ 与 $B - W_2$ 。

两条残差蛋白谱不再共享对照误差，253 个药物对的相关中位数降到 0.012。后续的药物相似分析不使用上述相关，而是在同一实验区块内直接计算两种药物的差：

$$(A - W) - (B - W) = A - B.$$

这样，共用的 Water 项在计算中会被完全抵消。

药物相似网络以每种药物为一个节点。对药物 i 和 j ，先在两者共有的每个完全相同实验区块 c 中计算蛋白谱的均方根差，再对所有共有区块取中位数并加负号：

$$S_{ij} = -\text{median}_{c \in C_{ij}} \sqrt{\frac{1}{|\mathcal{P}_{ijc}|} \sum_{p \in \mathcal{P}_{ijc}} [Y(i, c, p) - Y(j, c, p)]^2}.$$

其中， C_{ij} 是两种药物共有的数据来源、菌株、培养基、温度、时间、仪器和培养板组合， $\mathcal{P}_{ijc}$ 是该区块内两种药物都有实测值的固定蛋白集合。只有共同实测蛋白达到固定面板的 80% 时，这个区块才参与计算。因为均方根差前有负号， S_{ij} 越大，也就是越接近 0，表示两种药物的响应越相似。

仅看 S_{ij} 仍可能偏向那些与多数药物都很接近的网络中心节点。为扣除这种普遍相似倾向，每个训练折只用该折中的药物对拟合

$$S_{ij} = \mu + a_i + a_j + E_{ij}, \quad \sum_i a_i = 0.$$

其中， μ 是训练药物对的总体相似水平， a_i 和 a_j 分别表示两种药物各自的节点效应， $E_{ij} = S_{ij} - (\mu + a_i + a_j)$ 表示这一药物对超出普遍相似倾向的剩余部分。 $E_{ij} \leq 0$ 时，当前药物对的相似度没有超过节点效应给出的预期，不能作为额外特异关系的正向证据。 $E_{ij} > 0$ 只说明方向为正，不能单凭差值大小认定关系成立。

本实验没有在看过结果后另设一个 E_{ij} 数值门槛，因为不同训练折的相似度尺度并不完全相同。最终判断使用预先固定的整体标准：分子结构给出的候选药物排序，应当与去除节点效应后的响应排序一致，并在 10,000 次整种药物身份置换中达到 $p < 0.05$ 。

整种药物身份置换是把 23 个药物名称与 23 套完整的分子结构特征随机重新配对。每套结构特征内部保持不变，蛋白结果也不打乱，改变的只有“这套结构属于哪一种药”。每次随机配对在内层调参和外层验证的全过程中保持不变，然后重新完成模型选择和评分。如果正确的药物与结构对应关系确实提供了信息，真实数据得到的相关应当高于绝大多数错误配对。 $p < 0.05$ 表示 10,000 次错误配对中，得到同样高或更高相关的比例低于 5%。

验证药物 d 时， $\mu + a_d$ 对所有候选药物都是同一个常数，不影响排序，因此实际比较的响应分数为 $S_{dj} - \hat{a}_j$ 。Spearman 相关比较两个排序是否一致。在没有并列名次时，其计算式为

$$\rho = 1 - \frac{6 \sum_{j=1}^n (r_j - s_j)^2}{n(n^2 - 1)},$$

其中 r_j 和 s_j 分别是候选药物在结构排序和响应排序中的名次。 $\rho = 1$ 表示顺序完全一致， ρ 接近 0 表示没有稳定的排序关系， $\rho = -1$ 表示顺序完全相反。作为网络中心性诊断，只按候选药物与其他训练药物的总体相似程度排序时，23 次完整留出药物验证的平均 ρ 为 0.720。这个排序没有使用被留出药物的结构或机制信息，因此 0.720 反映的是原始响应网络受到较强节点中心性影响，不是结构模型的预测结果。这里所说的分子理化描述符共有 12 项，均可由分子结构计算，包括分子量、脂溶性、极性表面积、氢键供体数、氢键受体数、可旋转键数和环数等。用这些描述符计算候选药物的相似顺序，再与去除节点效应后的响应顺序比较，平均 Spearman 相关为 0.120。

按照上述方法进行一万次整种药物身份置换。 p 值按“错误配对后得到不低于 0.120 的次数”计算，即

$$p = \frac{1 + \#\{\rho_{\text{perm}} \geq 0.120\}}{10001} = 0.0661.$$

正确药物与这些描述符对应时，去除节点效应后的平均 Spearman 相关为 0.120。不过，在 10,000 次随机错配中，有 6.61% 也得到不低于 0.120 的相关，高于预先规定的 5% 判断线。因此，虽然观察到的相关为正，现有结果仍不能证明这些理化描述符能够稳定解释药物特异的蛋白响应相似性。

这一分析采用前文已经定义的共享响应轴分解。 G 概括多种药物共有的主要变化方向， $Q(d, c)$ 保留某种药物偏离共享方向的部分。网络节点检查进一步排除了网络中心节点造成的表面配对信号。这样的处理也回应了 Systema 对稳定基础状态和共享系统性变化的警示。[2,21]

问题二目前只能得到部分肯定的答案。药物身份确实对应一部分可重复的蛋白变化，但其中很大一部分属于多种药物共有的响应。去掉基础蛋白谱、共同响应和网络节点效应后，剩余的药物特异信号较弱，当前证据还不足以证明能够稳定预测每种药物独有的蛋白变化模式。

上面的 0.120 不是模型对 5,243 个蛋白的预测准确率，而是根据数据覆盖率选出的 3,234 个蛋白所计算的药物响应相似度。这个蛋白集合没有按变化幅度筛选，因此大量变化较小的蛋白可能冲淡少数高响应蛋白中的药物特异信号，不过这一可能性尚未经过独立验证。后续实验需要预先固定蛋白选择规则。例如，在每次完整留出一种药物时，只用其余训练药物选择变化较明显的蛋白，或者事先依据 GO 功能、通路和 STRING 网络关系把蛋白分组，再到被留出的药物上检验。这样可以进一步判断药物特异规律是否集中在少量高响应蛋白或特定功能模块中。问题三将在此基础上分别检验这些规律能否迁移到未见药物，以及菌株特征和已有响应能否用于未见菌株或新时间条件。

问题三：怎样利用现有数据规律和外部知识进行 OOD 外推？

这里的 OOD 包括未见药物、未见菌株和新时间条件，其中本项目最关注、难度也最高的是完全未见药物的扰动预测。问题二表明，当前数据中仍然保留了一部分较弱的药物特异变化。本节分三层继续验证。第一层不加入外部数据，只比较均值、Metadata Ridge、低秩模型和 MLP，判断简单模型能否从训练集中捕捉这些规律。第二层利用其他菌株、时间点、实测对照或早期状态，解决已知药物在新场景中的适配问题，不把它当作新药预测。第三层才面向完全未见药物：分子结构和相似药物用于寻找训练药物中的参照，知识网络沿“药物、靶点、通路、蛋白”关系查找机制联系，Qwen、Gemma 和 TxGemma 用来试探预训练中涌现的药物知识能否迁移到酵母蛋白质组。最后由多模型路由选择已经验证适用的预测分支。

现有方法迁移一：均值与 Metadata Ridge

Metadata Ridge 使用菌株、培养基、温度、时间、药物和观测来源等实验条件建立正则化线性模型，并对缺失率严格小于 80% 的 4,422 个蛋白分别拟合。对蛋白 p ，只使用该蛋白有实测值的训练样本集合 I_p ，求解

$$(\hat{\beta}_{0p}, \hat{\beta}_p) = \arg \min_{\beta_{0p}, \beta_p} \sum_{i \in I_p} (y_{ip} - \beta_{0p} - x_i^\top \beta_p)^2 + \alpha \|\beta_p\|_2^2.$$

其中， y_{ip} 是样本 i 中蛋白 p 的对数丰度， x_i 是该样本的实验条件编码， β_{0p} 是不受惩罚的截距， $\alpha = 1$ 控制系数收缩强度。验证时完整留出一种药物，再用其余药物训练和预测。

二次惩罚会把过大的系数向零收缩，降低相关条件特征和小样本造成的估计波动。这里沿用 Hoerl 与 Kennard 提出的 Ridge 方法，并针对蛋白缺失改为逐蛋白使用各自的有效样本拟合。[16]

Metadata Ridge 的最终蛋白丰度 PCC 为 0.985145，高于均值基线。合并 DMSO/Water 对照得到的内部相对变化 PCC 为 0.326278。按照表 7，Ridge 明显超过均值预测，输出覆盖完整，误差和预测幅度也比均值更合理，因此被选为 MiJiaoPredict 的 shared core。

当一种药物从未在训练中出现时，它只能使用“未知药物”这一统一编码，因此 Ridge 无法区分不同新药的特异作用。保留它作为基础模型，是因为它在小样本、相关条件和高维输出下较稳定。结构、知识或场景专家只有在相应验证中确有增益时，才在它的预测上进行修正。

现有方法迁移二：低秩模型与 MLP

这组实验先使用一个 384 蛋白的架构比较面板，而不是直接反复训练全部 5,243 个蛋白。384 个蛋白只根据蛋白列名的 SHA-256 哈希顺序固定选出，选择过程不读取蛋白丰度或模型结果，因此不是事

后挑选容易预测的蛋白。预设规则要求候选先在这个面板上通过验证，才运行全面板确认。本次没有候选通过，所以没有触发全面板实验。

MLP 是多层感知机。直接 MLP 把实验条件编码 x 输入一个带 $\tanh$ 激活的隐藏层，再一次输出全部蛋白的标准化丰度：

$$h = \tanh(W_1x + b_1), \quad \hat{y} = W_2h + b_2.$$

它不压缩蛋白输出，用来检验简单非线性映射能否超过线性的 Ridge。

低秩 MLP 先在每个训练折内对蛋白响应做奇异值分解，只保留前 16 个响应方向组成固定基 V_{16} 。网络不直接输出数百个蛋白，而是预测 16 个坐标 $q = f_\theta(x)$ ，再还原为

$$\hat{y} = qV_{16}.$$

这相当于先用少数共同变化模式表示蛋白响应，再学习实验条件与这些模式之间的关系。基 V_{16} 只由当前训练折计算，不使用被留出药物的结果。[21]

程序中名为 residual MLP 的第三个网络并不预测 Ridge 残差，而是在同一个 16 维空间中把预测拆成共享条件、菌株、药物及其交互项：

$$q = g(c) + e_s + e_d + e_s \odot h_s(c) + e_d \odot h_d(c) + e_s \odot e_d, \quad \hat{y} = qV_{16}.$$

其中 c 表示培养基、温度和时间等条件， e_s 与 e_d 分别表示菌株和药物。报告下文仍沿用程序名 residual MLP，也将它称为加性分解 MLP。三种模型回答的是三个不同问题：直接 MLP 检验非线性本身是否有用，低秩 MLP 检验先把输出限制在 16 个共同变化方向是否更稳，加性分解 MLP 检验把共享条件、药物、菌株及交互项分别建模是否有帮助。它们使用相同的实验输入、数据划分和接近的参数量，因此结果差异更能反映模型结构，而不是训练信息或模型规模不同。[17]

这里的错误对应关系对照是把训练集中的整套蛋白响应重新分配给别的实验条件，同时保持条件输入、网络结构和训练样本数不变。这样一来，药物、菌株和培养条件与蛋白响应之间的真实对应关系被破坏。三种 MLP 的正常训练结果都优于各自的错配对照，说明网络确实利用了部分条件信息，并非只在重复平均蛋白谱。

但是，在完整留出药物的主要比较中，直接 MLP 和低秩 MLP 的相对变化 PCC 分别比 Ridge 低 0.02682 和 0.02677，两者仅相差 0.00005。低秩模型原本希望把 384 个蛋白输出压缩成 16 个坐标，减少同时预测的输出数量，并过滤一部分测量噪声。如果 MLP 的主要困难只是输出太长，低秩版本理应明显优于直接 MLP。实际结果几乎相同，说明输出维度并不是主要限制。加性分解 MLP 比 Ridge 低 0.03551。一个可能原因是它同时估计共享条件、药物、菌株及多个交互项，而数据中只有 37 种独立药物，这些额外参数较难稳定学习。完整留出药物后，该药物的身份嵌入又必须按未知值处理，药物相关项不能直接使用，复杂分解因此没有带来优势。这个解释与当前结果一致，但仍需要更多药物和专门的消融实验确认。

低秩谱来自另一项对药物平均响应的描述性分析。该分析先计算 37 种药物各自在 384 个蛋白上的平均相对变化，再减去所有药物共有的平均变化，最后用奇异值分解寻找最主要的变化方向。前 2、4、8 个方向分别保留约 56%、72%、85% 的总平方变化。这里的“方向”可以理解为一组经常共同升降的蛋白组合，“总平方变化”表示这些组合能够概括原响应差异的比例。有效秩约为 9.28，表示这些响应的复杂程度大致相当于 9 个强度相近的独立方向，而不是 384 个彼此独立的蛋白变化。

这项分析说明已观测的药物响应可以用少量坐标近似表示，却不能保证模型能预测这些坐标。重构时，坐标是从已经看到的蛋白响应中计算出来的。面对完全未见的药物时，模型只能根据药物和实验条件输入推断坐标。如果输入中没有足够的新药信息，即使输出本身容易压缩，也仍然无法知道这个新药在每个低维方向上应取多大数值。

按照表 7，三种 MLP 通过了“不是随机学习”的检查，但都没有超过使用相同输入的 Ridge，因此没有通过“是否超过简单方法”这一项，当前不进入 MiJiaoPredict。




图 3: 相同输入与留出方式下, 三种 MLP 均未超过 Metadata Ridge

这组实验的直接结论是, 在只使用比赛元数据时, 三种 MLP 都没有超过线性 Ridge, 增加非线性结构没有带来优势。程序虽然把药物名称作为一个类别变量输入模型, 但这只是区分训练中已经出现的药物, 并不包含分子结构或作用机制。完整留出一种药物后, 该药名不在训练词表中, 只能被记为“未知药物”。模型仍然知道菌株、培养基、温度和时间, 却无法由药名判断这个新药与哪些训练药相似。

复赛数据即使不增加, 也可以补充药物侧输入。下一步可把 Morgan 指纹、理化性质、知识网络特征或语言模型产生的药物表示加入 Ridge、低秩模型和 MLP, 在相同的完整药物留出方式下重新比较。如果加入这些表示后的 MLP 超过使用同一表示的线性模型, 才说明非线性映射本身有帮助。如果两者都改善, 则更可能是新增药物信息起作用。现有结构和语言模型实验只显示局部或不稳定的增量, 因此这些表示值得继续验证, 但不能预先假定一定有效。当前能够确定的是, 只有药名类别和实验条件时, MLP 不如 Ridge。低秩可以减少输出数量, 却不能补上新药本身的信息。

现有方法迁移三: 分子结构与相似药物

这组实验先从 PubChem 取得药物结构, 再用 RDKit 计算两类分子特征。第一类是 512 位 Morgan 指纹。它把分子中每个原子半径为 2 的局部结构编码成一串 0 和 1, 两个药物的指纹相似度用 Tanimoto 系数计算:

$$T(a, b) = \frac{|F_a \cap F_b|}{|F_a \cup F_b|},$$

其中 F_a 和 F_b 是两个药物指纹中取值为 1 的位置集合。第二类是 10 个理化描述符, 包括分子量、脂水分配系数、极性表面积、氢键供体和受体数量、可旋转键数量、环数量、重原子数量、碳原子中 sp^3 杂化的比例和分子形式电荷。这些描述符不是指纹, 而是对分子大小、极性、柔性和电荷等性质的数值概括。[5]

我们用上述特征比较三种结构模型。第一种是相似药物迁移。程序先只根据菌株、培养基、温度和时间得到基础预测, 再计算每个训练药物相对于该基础预测仍未解释的平均变化。面对一个新药时, 程序找到 Morgan 指纹最相似的 5 个训练药物, 并按 Tanimoto 相似度的平方加权借用这些变化:

$$\hat{z}_q(x) = \hat{z}_{\text{context}}(x) + \frac{\sum_{d \in N_5(q)} T(q, d)^2 r_d}{\sum_{d \in N_5(q)} T(q, d)^2}.$$

这里 r_d 是训练药物 d 尚未被实验条件解释的平均变化, $N_5(q)$ 是新药 q 最相似的 5 个训练药物。所谓“结构近邻残差迁移”, 就是在实验条件预测的基础上, 借用相似训练药物留下的修正量。没有结构、没有可用近邻或相似度为零时, 不进行这一步修正。

第二种是 CPA 风格的相加模型。CPA 的核心思路是把扰动信息和细胞状态分别编码, 再组合起来预测响应。对应到本题, 程序把菌株、培养基、温度和时间形成的实验条件预测, 与药物结构形成的预测相加:

$$\hat{z} = b + W_c x + W_s h(s) + W_m m.$$

其中 x 是实验条件, s 是 522 维分子特征, $h(s)$ 是只用训练药物把这些特征压缩到最多 16 维后得到的药物 embedding, m 用来标记结构缺失。第三种模型在此基础上加入 $h(s)$ 与菌株、温度和时间乘积

特征，使同一个分子特征可以在不同菌株或温度下产生不同影响。先把 522 维结构压缩到最多 16 维再计算这些乘积，是为了控制参数数量，因此称为“低秩交互”。本项目只借用了 CPA 的组合思想，没有复现其单细胞生成器、剂量模块和对抗训练，所以称为 CPA 风格模型，而不是完整 CPA。[3,4]

此外，我们单独测试了冻结的 32 维 chemCPA 药物 embedding。“冻结”是指直接使用预训练模型为每种药物生成的 embedding，不在酵母数据上更新 chemCPA 参数，后面只训练一个小型预测模型把该 embedding 转换成蛋白变化。这个实验与前述 Morgan 和理化特征模型分开评价，不能把它们当成同一个模型。[4]

验证时每次完整留出一种药物，使模型在训练中看不到该药的蛋白结果。我们还设置两种对照。药物结构错配保持每条分子特征不变，但随机交换它属于哪一种药。随机指纹则保留相同的向量长度和稀疏程度，却去掉真实化学结构。如果正确结构不能稳定超过这两种对照，表面的提高就可能来自增加了输入维度、结构缺失模式或模型容量，而不能说明模型真正利用了药物的分子信息。

第一项实验使用 384 个预先固定的蛋白，检验结构模型能否预测完整留出的新药。这里的 Ridge 是 Metadata Ridge。它把药物名称、菌株、培养基、温度和时间编码成数值变量，再用线性回归预测蛋白变化。待验证药物在训练中没有出现，因此药物名称只能进入“未知药物”位置，但其余实验条件仍然可用。严格的 PubChem/RDKit 映射为 25/37 种药物提供了结构，其余 12 种没有可靠结构时按预先规定回到不使用结构的预测。全部 37 种药物仍共同计分。合并溶剂对照下的 Raw-FC PCC 分别为 Ridge 0.255488、Tanimoto 近邻 0.251053、CPA 风格模型 0.248201 和低秩交互 0.247908，三个结构模型都没有超过 Ridge。




图 4: 两项分子结构实验的内部比较。横条表示相对各自对照的变化，标注数字为绝对分数。左右两图的蛋白范围、药物范围和指标不同，只能在各自图内比较。

第二项实验进一步追问，在同一实验条件下，分子结构能否帮助选择更合适的训练药物。它采用另一套经过审计的普通有机结构数据，其中 26/37 种药物可以可靠对应到理化特征和 Morgan 指纹，其余 11 种因无法可靠映射或不适合普通有机指纹而不进入这项比较。“同条件平均”是指在菌株、培养基、温度、时间和时间单位完全相同时，先计算其他训练药物尚未被基础模型解释的变化，再对这些变化取平均。12 项理化特征模型改为根据分子量、LogP、极性表面积、氢键和分子柔性等性质寻找相似训练药物。混合模型则使用 75% 的理化相似度和 25% 的 Morgan 相似度选择近邻。

三项分数的含义并不相同。0.438834 是不使用分子信息的同条件平均，0.441077 是加入 12 项理化特征后的分数，0.441492 是加入理化特征与 Morgan 指纹混合相似度后的分数。因此，分子信息带来的额外分数为

$$\Delta_{\text{PhysChem}} = 0.441077 - 0.438834 = 0.002243, \quad \Delta_{\text{blend}} = 0.441492 - 0.438834 = 0.002658.$$

这里没有直接减去 Ridge 的 0.423623。Ridge 提高到同条件平均的 0.438834，增加的 0.015211 主要来自完全相同实验条件下的训练药物信息。PhysChem 相对 Ridge 的总提高为 0.017454，其中 0.015211 来自同条件平均，另有 0.002243 来自加入理化描述符。混合模型相对 Ridge 的总提高为 0.017869，其中 0.015211 来自同条件平均，另有 0.002658 来自理化描述符与 Morgan 指纹。后面仍需通过药物身份错配检验，才能判断这两个较小增量是否稳定来自正确的分子信息。

药物身份错配检验把 26 种药物与整套分子特征随机重新配对，并保证没有药物仍拿到自己的特征。每次错配都完整跑过相同的五个留出折，共进行 20 次。理化模型的真实分数只排到 21 个结果中的第 5 名，有 4 次错配结果不低于真实结果。理化与 Morgan 混合模型排第 3 名，也有 2 次错配结果不低于真实结果。预先设定的要求是正确配对必须排第 1 名，所以两种模型都没有通过这项检查。它们相对基础模型的残差 PCC 增量也分别只有 0.003825 和 0.004516，低于预设的 0.005。

第三项实验覆盖 23 种能够对应到预训练 chemCPA 输入的药物。每次完整留出一种药物后，基线只根据其余 22 种训练药物在相同实验条件下的平均蛋白响应进行预测，不使用被留出药物的分子信息。候选模型则冻结 chemCPA 编码器，提取该药物的 32 维 embedding，并用它从训练药物中迁移响应。与上述基线相比，chemCPA 的平均 MSE 仅改善 0.025%，平均 PCC 下降 0.000907，且只有 10/23 种药物的 MSE 更低，因此没有形成稳定增益。

三项实验没有直接合成一个模型，是因为它们回答的问题不同。第一项检查结构模型在全部药物中的整体表现，第二项只在结构覆盖药物中追问分子相似性是否超出同条件共享变化，第三项检验预训练 chemCPA embedding。三者的药物覆盖、蛋白范围、预测目标和评分指标均不相同，固定平均会把结构缺失与不同指标混在一起，也可能掩盖某个分支的失败。MiJiaoPredict 因此把它们保留为独立候选专家，只有某个分支在自己的适用范围内通过验证后才会启用，不进行无条件聚合。

表 8: 精确条件残差实验的结构覆盖范围与结论边界

项目	具体内容
具备可用结构输入的 26 种药物	Artemisinin、Trifluoperazine dihydrochloride、Hoechst 33258、LY 294002 hydrochloride、Parthenolide、Brefeldin A、Nystatin dihydrate、Emodin、EDTA、Nocodazole、Wortmannin、Rapamycin、Cyclopiazonic acid、Haloperidol、Staurosporine、Sorbitol、Amiodarone hydrochloride、Desipramine hydrochloride、Anisomycin、Clotrimazole、Nigericin、Trichostatin A、4-Hydroxytamoxifen、Clomiphene citrate、Dyclonine hydrochloride、Harmine hydrochloride
“精确条件”的含义	菌株、培养基、温度、扰动时间和时间单位全部相同。只有满足这些条件的训练药物才能向待预测药物提供残差。
总体方向性信号	在上述 26 种药物组成的总体中，理化近邻相对同条件平均增加 0.002243，5 折中 4 折为正。理化与 Morgan 混合增加 0.002658，5 折中 3 折为正。
目前不能确定的内容	冻结结果没有保存逐药物、逐条件预测和增益，无法据此点名哪些具体药物获益。表中的药名表示具备可用结构输入，不表示该药已经单独验证成功。

综合来看，结构模型在上述 26 种药物组成的总体中出现了小幅方向性增量，但全部 37 种药物共同比较时没有超过 Ridge，正确结构也没有稳定胜过身份错配。因此 MiJiaoPredict 保留 structure expert 接口，但当前默认关闭。复赛所说的“扩大结构覆盖”，是为目前缺少可靠结构输入的药物补充经过核实的 PubChem parent、SMILES、Morgan 指纹和理化特征。后续还将按分子主骨架成组留出整类药物，增加药物与结构错配次数，并尝试先预测预先定义的蛋白模块而不是一次预测数千个单蛋白，再决定是否启用该专家。

现有方法迁移四：时间、菌株、对照与早期状态专家

这组实验不处理完全无信息的新药，而是利用查询场景中额外可获得的实测信息：同一已见药物在其他菌株中的响应、同一实验条件的其他时间点、同条件对照，或同一样本的早期蛋白状态。

这样设计的原因是：虚拟酵母路线强调利用多时间点、多菌株和连续实验反馈建立可更新的细胞状态模型。公开的 1,011 株酵母资源也说明菌株遗传背景具有系统性差异。因此，把菌株迁移、时间插值和前缀预测拆成三个任务分别验证。它们分别考察同一种已见药物能否推广到新菌株、已有时间点能否帮助预测其他时间点，以及早期蛋白状态能否帮助预测后续状态。这些实验利用的是同一种药物在其他菌株、其他时间点或早期时间点的实测数据，验证的是已有实验轨迹能否帮助模型适配新条件，不能代表模型可以在完全没有该药实测结果时预测一种全新药物。[1,10]

这些结果必须和模型读取的实测信息放在一起理解。表 9 列出了每项实验的输入、预测对象和比较结果。

表 9: 场景专家与同药少样本校准实际使用的信息

实验	模型额外读取的实测信息	要预测的对象	与不读取这些信息的比较模型相比
新菌株预测	同一种已见药物在其他训练菌株、相同实验条件下已经测得的药物相对变化	该药物在一个完整留出的新菌株中的响应	药物相对对照变化的 PCC 提高 0.030936, 4/4 个留出菌株均改善
时间预测	同一药物、菌株、培养基和温度组合在其他时间点已经测得的响应。程序先把这些响应压缩为 32 个主要变化方向, 再沿对数时间插值	同一组实验条件下被留出的时间点	药物相对对照变化的 PCC 提高 0.044988, 6/6 个留出时间点均改善
早期状态预测	同一实验条件在 30、60、90 或 120 分钟已经测得的 384 个蛋白状态, 以及目标时间	同一条件的后续蛋白状态	未来变化的 PCC 提高 0.08840, 但最终蛋白丰度 PCC 下降 0.00020, 药物相对对照变化 PCC 下降 0.00533
同条件对照校准	数据来源、仪器、培养板、菌株、培养基、温度和时间均相同的实测 DMSO 或 Water 对照蛋白谱	同一条件下的药物处理结果	在处理与对照使用同一组重复样本计算时通过检查, 但更换聚合方式后不稳定, 因此只作为有实测对照时的条件分支
同药 16-shot 校准	对每种完整留出的药物, 先提供该药在 16 个实验条件下已经测得的蛋白结果。其余模型和先验只使用另外 36 种药物拟合	同一种药物其余尚未提供结果的实验条件	MSE 从 0.390279 降至 0.273764, 下降 29.85%。对 50 组固定支持条件取平均后, 37/37 种药物均改善

因此, 这些实验并不是完全未见药物的零样本预测。新菌株实验会读取同一种药物在其他菌株中的响应, 时间实验会读取同一实验条件的其他时间点, 对照实验和 16-shot 校准也分别读取同条件对照或同药的 16 个已测条件。早期状态实验只把“从已经测得的早期状态到后续状态的变化”预测得更准, 并没有改善后续时点的最终蛋白丰度, 也没有改善药物处理相对对照的整体变化。因此, 它只适用于同一实验已经取得早期蛋白测量、目标是继续预测后续变化的情况。总体来看, 这些实验说明少量同药观测可以帮助校准后续预测。MiJiaoPredict 只在相应实测输入存在时调用这些模型, 否则使用不读取这些额外数据的基础预测。

现有方法迁移五：知识网络与公共机制

这部分先做了两类知识实验。第一类从药物出发, 将 STITCH 中的酵母药物靶点连接到 STRING 蛋白关联网络, 并把直接靶点和一步相邻蛋白转换为药物特征。第二类从输出蛋白出发, 使用 GO 和 Reactome 中已经整理的生物过程给蛋白分组。这里的“通路”是数据库中被归入同一生物过程的一组蛋白, 例如翻译、细胞周期或应激反应。“蛋白模块”指模型中共享同一组参数的蛋白组。另一个菌株实验还把每株酵母在各功能组内的功能缺失、移码和拷贝数变化汇总成“菌株变异负担”, 用于预测新菌株, 不属于下面的五视图新药实验。[6–10]

STITCH 网络实验要求药物名称能够唯一对应到数据库化合物、至少有一个综合分数不低于 400 的酵母靶点, 并且该靶点能够进入 STRING 网络。37 种药物中只有 14 种同时满足这些条件, 因此其余药物只能回到 Ridge。完整留出药物时, 靶点网络模型的相对变化 PCC 为 0.24894, 低于 Ridge 的 0.25756。

GO 通路实验共使用 77 个可命名的酵母生物过程。模型先共享前面的计算层, 再为不同通路中的蛋白设置各自的输出层。作为比较, “单一输出层”模型让全部蛋白共用一个输出层, 并把参数量控制在接近范围。另一项对照在保持各通路蛋白数量近似不变的情况下, 随机打乱蛋白属于哪个通路。整种药物未知时, 正确通路模型的 PCC 为 0.23160, 比错误通路的 0.22660 高 0.00500, 但仍低于单一输出层的 0.24066 和 Ridge 的 0.25628。由于正确和错误通路使用相同的数据划分、模型大小与训练方法, 两者唯一的主要差别是蛋白分组是否正确。只有正确分组持续更好, 增量才可以归因于通路知识。本实验只出现弱差异, 尚不足以启用该模型。

最后又把五类药物信息放进同一个联合模型: 由分子结构预测的公共酵母蛋白特征、本地 Qwen 的 49 维机制特征、STITCH-STRING 网络特征、Qwen 与 Gemma 的共识和分歧特征, 以及 42 个直接靶

点蛋白特征。Morgan 指纹作为额外比较，不属于这五类。联合预测写为

$$\hat{y}_{\text{joint}} = \hat{y}_{\text{base}} + \sum_{v=1}^5 w_v m_v \hat{r}_v, \quad w_v \geq 0, \quad \sum_{v=1}^5 w_v \leq 1. \quad (1)$$

其中 $\hat{y}_{\text{base}}$ 是 Ridge 加训练数据内部条件平均得到的基础预测， $\hat{r}_v$ 是第 v 类药物信息给出的修正， m_v 表示该药是否具有这一类信息，权重 w_v 只用训练药物内部的验证结果确定。某类信息缺失时不补造特征，权重没有用满的部分也不产生修正。




图 5: 公共知识实验的 Raw-FC PCC。A、B 报告各自实验中的绝对 PCC，C 报告相对同一五视图实验中 Metadata Ridge core 的 PCC 变化。

图 5 显示，五视图联合相对 Metadata Ridge core 增加 0.01850，但不使用任何外部视图的共享条件基础预测本身也增加 0.01850。联合模型相对这个更合适的比较对象实际上下降约 0.000002，药物特异平均响应只增加 0.000284，且只有 2/5 折改善。五个外层学到的视图总权重仅为 0.0014 到 0.0523，也就是约 94.8% 到 99.9% 的预测没有采用这些外部修正。

网络中连接很多药物和蛋白的热门节点确实可能制造表面相似。现有实验已经加入“连接数量相近但关系错误”的网络对照，正确网络没有稳定胜过它。下一步还可以在传播前减去节点连接数带来的平均效应。后续所说的“预先定义机制簇和蛋白模块”，是指在查看预测结果前，按共同靶点或 GO/Reactome 标签固定药物组和蛋白组，再把同一机制组的全部药物一起留出，检验模型能否推广到未见过的一类作用机制。当前完成的是逐药物留出，还没有完成这种整机制组留出。因此知识专家暂不进入 MiJiaoPredict，但保留扩大可靠靶点覆盖、去除热门节点效应和整机制组验证后的重测接口。

现有方法迁移六：本地 Qwen、Gemma 与 TxGemma

这部分包含三项不同实验。第一项使用本地 Qwen3 8B 和 Gemma 12B，但没有直接抽取模型隐藏层的 embedding。程序给每个模型一组固定问题，请它根据药物名和菌株名判断 24 个酵母生物过程可能被增强还是抑制，并给出置信度。24 个药物方向分数、1 个置信度和 24 个经过菌株信息调整的方向分数组成 49 维数值特征。“双模型共识”也不是模型投票，而是把 Qwen 与 Gemma 的 49 个数值逐项取平均。

这些数值怎样变成蛋白预测也保持一致。每次完整留出一组药物后，程序只用其余药物把 384 个蛋白的响应压缩成 16 个主要变化方向，再用 Ridge 根据实验条件和 49 维药物特征预测这 16 个系数，最后还原为蛋白预测。比较模型使用完全相同的压缩方法和 Ridge，只去掉这 49 维特征。这样比较时，结果差异来自语言模型给出的药物信息，而不是后端预测模型大小不同。第二项实验不直接预测系数，而是计算新药与训练药物在 49 维特征上的余弦相似度，寻找最相似的训练药物，再加权迁移它们已经测得的响应残差。

第三项实验使用 TxGemma。TxGemma 是在治疗领域数据上训练的模型。固定药名提示经过模型后得到 2,304 维隐藏层 embedding，模型参数全程不更新。每次完整留出一种药物时，只用其余 36 种药物把 embedding 降到 8 维，再由 Ridge 预测 3,439 个蛋白。因此，这三项实验都让语言模型负责提供药物信息，蛋白数值关系仍由训练药物学习，而不是让语言模型直接生成数千个蛋白值。[11,18,19]

本地 Qwen/Gemma 的结果不理想。双模型平均特征使相对变化 PCC 下降 0.01414，5 折均未改善，最终丰度 RMSE 增加 0.12595。相似药物检索在严格留出药物后也没有稳定增量。这说明两个模型对同一药物给出相近描述，并不等于这种描述与酵母蛋白响应一致。

TxGemma 的平均 MSE 从 0.047869 降到 0.045495，点估计改善 4.96%。但按药物计算的 95% 置信区间为 [-0.002219, 0.007338]，其中包含 0，也同时包含改善和恶化的可能，因此现有 37 种药物还不能确认平均增益稳定存在。37 种药物中只有 15 种改善，也低于预先要求的 24 种。进一步把每种药物的改善值随机翻转正负号，得到同等或更大平均改善的概率为 $p = 0.1756$ 。这个数值高于常用的 0.05，因此没有排除偶然波动。

高响应蛋白的检查也发现了一个重要问题。TxGemma 选出的 top-5 蛋白优于随机挑选，但没有超过“训练药物中经常强烈响应的蛋白”这一简单规则，升降方向也在 37/37 种药物上几乎总是预测上升。针对“为什么不先减去这些常见高响应蛋白再做”的问题，后续实验已经补做了这一步。每个留出折只用其余训练药物计算第一条共享统计响应轴，再把完整预测分成共享轴部分和与该轴垂直的药物特异部分。完整 MSE 改善为 0.002375，其中共享轴贡献 +0.003478，药物特异部分贡献 -0.001103。也就是说，去掉多种药物共有的高响应方向后，TxGemma 不仅没有改善，反而略微变差。

因此，本地 Qwen/Gemma 和 TxGemma 都已经产生过完整留出药物预测，但当前不作为 MiJiao-Predict 的启用专家。下一步的 base Gemma 对照，是使用与 TxGemma 属于同一模型家族、参数规模接近但没有治疗领域训练的基础 Gemma，并保持相同提示、embedding 提取、8 维压缩和 Ridge 预测流程。这样才能判断差异是否来自治疗领域训练。RAG 则会先从 STITCH、STRING、GO、Reactome 或药物文献中检索有来源的靶点和通路证据，再交给本地模型生成特征。若这些可追溯信息在新药验证中形成稳定增量，可进一步尝试 LoRA。LoRA 只训练少量低秩适配参数，可以在大部分模型权重保持不变的情况下，让药物 embedding 更贴近酵母机制任务。现有数据只有 37 种独立药物，直接做 LoRA 很容易记住药名，因此应先增加公共机制监督和独立药物，再评估是否启用。



图 6: 按训练药物计算共享响应轴后，TxGemma 的点改善主要落在共享轴上，轴外药物特异残差没有改善

现有方法迁移七：四模型组合与动态路由试验

这项实验做的是一个小型的“四模型路由试验”，没有把本项目所有模型都放在一起。它只检验已见药物和已见菌株形成的新实验组合，使用同一组 384 个蛋白。在同一个查询条件下，四个模型分别给出一份蛋白预测：

- Metadata Ridge，用正则化线性回归学习实验条件与蛋白响应的关系。
- C0 条件模型，只使用实验条件，不依赖查询样本的实测对照。
- 普通 MLP，参数量与 C0 接近，用来比较一般非线性网络。
- 低秩 BasisMLP，将蛋白响应压缩到少数统计方向，训练时更重视变化幅度较大的蛋白。

实验比较三种使用这四个模型的方式：

- **单模型**：始终使用 Metadata Ridge。
- **固定组合**：四个模型按一组固定比例加权，所有查询都使用同一组权重。
- **动态组合**：根据药物、菌株、培养条件和四个模型预测结果的分歧，为每个查询分别计算四个权重。

最终预测为

$$\hat{\mathbf{y}}(x) = \sum_{e=0}^3 w_e(x) \hat{\mathbf{y}}_e(x), \quad w_e(x) \geq 0, \quad \sum_{e=0}^3 w_e(x) = 1. \quad (2)$$

不同模型的偏好不同。Ridge 更稳定，非线性模型可能更适合某些实验条件，BasisMLP 则更关注高响应蛋白。如果固定平均，不适用某个查询的模型也会影响结果。因此，该试验要回答的问题是，能否在不读取查询真实结果的前提下，仅根据查询条件和模型分歧，判断当前查询更适合哪个模型或哪种组合。GRPO 路由器用一个小型网络学习这四个权重，训练依据只来自训练数据内部留出的预测结果。[20,22]

Metadata Ridge 的评分为 0.592901。固定四模型组合为 0.593379，比 Ridge 高 0.000478。GRPO 动态路由再比每个留出折中较强的 Ridge 或固定组合高 0.001208，两个留出折都有改善，但没有达到实验前规定的 0.003 最低增量。后续又试了只在 Ridge 与 BasisMLP 之间选择修正幅度的离线 bandit，结果比强静态模型低 0.000112。按 GO 蛋白组分别选择模型的试验也没有产生可区分的候选预测。

四模型可以通过统一接口组合，动态选择也出现了小幅正增量。但这一结果只来自 384 个蛋白、两个留出折和已见药物与菌株的新组合，增量也未达到预设标准，因此还不能说动态路由稳定优于 Ridge 或固定组合。当前 MiJiaoPredict 仍使用手工证据门控。后续可以继续扩展专家，并根据查询条件、专家分歧、历史验证结果和不确定性，探索动态门控或智能体路由。Metadata Ridge 仍保留为完整基础预测，避免未经验证的专家降低整体结果。

创新探索一：药物侧因果链与磷酸化中间表示

这项探索希望把“查资料”和“预测蛋白”连成一条可以逐段检查的机制链：

$$\text{药物及公开证据} \rightarrow \text{靶点} \rightarrow \text{激酶、转录因子或通路} \rightarrow \text{蛋白模块或少数关键蛋白}. \quad (3)$$

STITCH 提供药物与蛋白关系，STRING 提供蛋白关联，GO 和 Reactome 提供生物过程分组。语言模型的作用是搜索、整理并连接这些公开信息，提出类似研究人员工作时可能会写下的候选机制，例如“药物抑制某靶点，继而降低某通路活性，最后使一组应激蛋白上升”。它负责提出有来源、带方向、允许弃权的生物学假设，真正的蛋白变化幅度仍由训练药物中的 Ridge 学习。这样可以把大量资料检索和候选机制整理加速为自动化流程，但语言模型提出的链仍然是假设，不等于已经证明因果。[6-9,18,19]

为避免模型看过结果后再修改故事，程序在读取被留出药物的蛋白结果前，先保存每种药物的靶点、通路、蛋白模块和预期升降方向。30/37 种药物得到方向机制包，7 种证据不足时主动弃权。机制包被转成 28 维数值特征，再由 5 折完整留出药物的 rank-4 Ridge 预测蛋白变化。验证时加入两个容易理解的对照：药物身份错配是把 A 药的整套机制包交给 B 药，检查随便换一个药物故事是否也能得到相同增益。方向反转则保留靶点和通路，但把预期上升改成下降、下降改成上升，检查模型是否真正使用了方向信息。

现有结果中，机制包使条件残差提高 0.027857，5/5 折为正，但药物相对对照的整体变化下降 0.000992。身份错配和方向反转检验的 p 值分别为 0.391 和 0.406，说明正确机制包没有稳定胜过这两个错误对照。因此，目前只能说语言模型产生了可检验的机制候选，不能说它已经找到了可靠因果方向，也暂不作为默认预测专家。

磷酸化实验验证的是这条链的另一个局部环节。公开磷酸化蛋白组记录药物处理后磷酸化肽的变化，可作为靶点作用到总蛋白变化之间的一种候选中间状态。比赛数据本身没有这一列。实验在已经取得同一种药物实测磷酸化数据时，用这些外部信号预测该药的总蛋白变化。16 种可匹配药物中，误差

平均改善 2.7655%，95% 置信区间为 0.9832% 到 5.1628%，11/16 种药物改善，药物身份错配检验为 $p = 0.005$ 。这说明“实测磷酸化状态到总蛋白变化”这一段具有局部价值，但还没有解决如何仅根据新药信息预测其中间状态。

下一步不只扩大磷酸化数据。更有价值的路线是让带检索功能的本地模型从药物结构、靶点文献、转录组、磷酸化、激酶或转录因子活性、化学基因组和代谢数据中提出多条相互竞争的机制链，并保留每一步的来源。预测目标也先从 5,243 个单蛋白收缩到预先确定的 GO/STRING 模块，或由公开机制链在不读取待测药物蛋白结果的前提下提出药物特异 top-5 候选蛋白，同时预测升降方向。随后用公开数据逐段检查“药物到中间状态”和“中间状态到蛋白模块”，再用身份错配、方向反转和无关机制对照淘汰只会讲合理故事的链。若这些较小目标稳定通过验证，因果链专家再接入 MiJiaoPredict，并进一步探索由智能体自动检索证据、提出反事实机制和选择下一项验证实验。

创新探索二：分开预测共同响应与药物特异变化

这项探索要区分两类信号：多种药物共有的变化，以及某一种药物不同于其他药物的变化。程序先减去相同实验条件下训练药物的平均变化，再把剩余响应分为共同统计方向和方向之外的药物特异残差。前者表示扰动整体有多强，后者表示该药与其他药有什么不同。两部分只用 Ridge 和低秩模型预测，因为独立药物仅 37 种，而输出有 3,448 个蛋白，较大的神经网络很容易记住训练药物。[2,21]

PCA 和低秩分析表明，蛋白响应主要集中在少数统计方向上。TxGemma 的 4.96% 平均误差改善也主要来自共同方向，去掉它以后，药物特异残差没有改善。因此两部分必须分开评分，否则模型只学会常见扰动也可能得到较高分。

实验开始前规定，每次留出药物和每次内部参数选择都至少要在原定 3,448 个蛋白的 75% 上评分，即 $\lceil 0.75 \times 3,448 \rceil = 2,586$ 个。这样可防止缺失较多的药物只在少量容易预测的蛋白上得分。实际有 3/37 次完整药物留出和 108/1,332 次内部参数比较不满足要求，所以实验在汇总性能和置换检验前停止。

这项实验原本想为 MiJiaoPredict 准备两个分工不同的专家。共同响应分支负责预测多种药物通常都会出现的变化，用来估计细胞受到扰动的总体程度。药物特异分支负责预测某一种药物偏离共同变化的部分，用来区分不同药物。把两部分分开，是为了避免模型只学会“多数药物都会出现的反应”却仍得到较高分。如果两个分支分别通过验证，它们可以作为共同响应专家和药物特异修正专家接入 MiJiaoPredict。实际运行中，部分药物的蛋白缺失过多，实验在比较两个分支的性能前就停止了。因此，目前还不知道这种拆分能否改善预测，当前版本也没有启用这两个专家。

下一步将在现有数据上另行设计模块级实验。GO 按共同生物过程分组，STRING 按蛋白关联形成网络模块。程序会在查看模块性能前固定分组、最低成员覆盖数和评分规则，再预测模块的平均变化。这样既可减轻单个蛋白偶发缺失的影响，也更容易解释通路整体变化。新实验仍保留全部 37 种药物，并继续分开评分共同响应和药物特异变化。若覆盖仍不足，就报告无法评价，不删除药物或放宽规则。

总模型进度：MiJiaoPredict

MiJiaoPredict 借鉴 MoE 的“不同输入调用不同专家”思想，但目前不另行训练难以解释的门控网络。Metadata Ridge 先生成完整预测，确定性路由器再检查药物、菌株、时间、对照、早期状态和特征是否可用。只有专家已经在相应范围通过验证时才进行修正，缺少输入、验证未通过或运行异常时保留 Ridge。这样既能利用专家在限定场景中的优势，也保留明确的回退规则和逐条记录。[20]

v0 已实现 shared core、残差专家、替换专家、路由记录和异常回退。当前可启用的正向分支包括已见药物到新菌株、已有实验轨迹到新时间点、实测对照和同药少量真值。结构、知识和语言模型已经完成实验，但尚未稳定通过表 7 的检查，因此暂不启用。专家状态与当前输入同时满足要求时才调用，其余情况继续使用 shared core。

复赛首先继续推进智能体因果链。智能体从靶点文献和公开组学资料中检索证据，提出带来源的机制链，再预测少量候选蛋白、蛋白模块及升降方向。身份错配、方向反转和留出验证用于排除只会生成合理故事、却没有预测价值的机制。通过这些检查后，再把机制证据用于 MiJiaoPredict 的专家选择。

RAG 和 LoRA 可以作为后续实现方式，但不预先假定一定有效。

全部方法的阶段性结果总表

表 10: 全部主要方法、关键数据与当前状态（各行协议不同，不按绝对数值排序）

方法	验证范围	关键数据	当前状态/下一步
均值基线 药物身份复现 Metadata Ridge	全体蛋白 TRAIN 内跨样本 4,422 蛋白	PCC 0.9411, 逐蛋白 R^2 -0.0413 同药 0.378, 异药 0.044, AUC 0.939 最终丰度 PCC 0.985145, 内部相对变化 0.326278	仅说明基础谱强, 保留为诊断 证明数据含药物信号 MiJiaoPredict shared core
低秩/MLP 结构与 chemCPA	384 蛋白, 完整留出药物 37 药, 子集覆盖 23-26	相对 Ridge -0.02682 至 -0.03551 全药 0.251053/0.248201/0.247908, 低于 Ridge 0.255488, 子集最多 +0.002658, 错配 未过	未晋级, 补做药物 embedding 对照 未晋级, 做新骨架与模块输出
菌株与时间专家	4 菌株, 6 时间折	相对变化 +0.030936 (4/4) 和 +0.044988 (6/6)	限定范围启用
早期状态与 16-shot	同条件早期蛋白, 每药 16 条自 身条件	未来变化 +0.08840, 16-shot MSE -29.85% (37/37)	有实测信息时使用, 不是零样本
STITCH/STRING 与 GO Qwen/Gemma 与 TxGemma	14/37 药, 384 蛋白 37 药	网络 0.24894 低于 Ridge 0.25756, 正确 GO 分组比错误分组 +0.00500 本地特征 -0.01414 (0/5), TxGemma MSE 点改善 4.96% (15/37, $p=0.1756$)	覆盖不足, 仅见弱模块信号 未晋级, 先做 RAG 和 base Gemma 对照
四专家/GRPO 多层去中心	384 蛋白, 2 折已见组合 TRAIN 内诊断	static +0.000478, GRPO +0.001208 共用对照 0.405→ 独立对照 0.012, 节点效应后 0.120	未过 +0.003 门, 继续验证路由策略 已用于排除假相关
因果包与磷酸化链	30/37 有模块, 16 药有磷酸化	因果包 +0.027857 但错配未过, 磷酸化误差改 善 2.7655% (11/16, $p=0.005$)	机制候选, 改做模块和药物特异 top-5
共享轴/特异残差 MiJiaoPredict v0	3,448 蛋白 手工证据门控	3/37 外层, 108/1,332 内层覆盖失败 core、专家、审计和异常回退接口已完成	不可估计, 改模块输出 当前总模型, 继续扩展因果链与智能体

五、复现与开放计划

5.1 复现方式

代码层使用锁定依赖。研究实验注册表通过 Experiment.run(RunContext) 组织证据回放, Metadata Ridge 提供独立 train/predict/-submission CLI, MiJiaoPredict v0 提供 predict、predict_with_audit 和 model_manifest。其他已报告性能的模型均在各自冻结协议下真实运行并产生预测, 只是不会因一次局部点值改善就自动晋级。现已验证 MiJiaoPredict 7/7 项接口测试及既有 research_code 118/118 项测试, 历史分支若仅保留冻结证据, 会明确标注 reconstruction/adapter。

```
cd /path/to/GOAI-virtual-yeast-project/research_code
uv sync --locked --extra dev
uv run --locked python -m unittest discover -s tests -q
uv run --locked python research_cli.py list
uv run --locked python -m unittest mijiao_predict_v0.test_mijiao_predict -v
```

实际运行时, 可用 train-metadata-ridge --help 和 predict-metadata-ridge --help 查看授权数据路径、模型目录与 submission template 参数。表 11 集中列出主要实验入口。“直接运行”表示可从当前代码重新执行, “冻结回放”表示复核已保存的结果和校验值。

表 11: 主要方法的程序入口

方法	主要函数或命令	文件或目录
数据诊断	均值、重复性、去中心	research_code/experiments/, train-only-drug-repeatability-audit-v1/, residual-drug-signal-diagnostics-v1/
基础模型	Ridge CLI, Ridge/MLP benchmark	research_code/research_cli.py, pipeline/competition_baseline.py, fair-architecture-benchmark-v1/
外部药物信息	结构、网络、Qwen/Gemma	structure-generalization-v1/, contextual-residual-fusion-v2/, drug-target-localnet-v1/, dual-local-llm-mechanism-v1/
场景与创新实验	strain/time、GRPO、因果包、共享轴	official-dataset-local/, rl-feasibility-search-v1/, causal_packet_prior/, two_stage_generic_residual_v1_20260814/
MiJiaoPredict	predict(), predict_with_audit()	research_code/mijiao_predict_v0/mijiao_predict.py, test_mijiao_predict.py

MiJiaoPredict v0 和 Metadata Ridge 可以直接运行。MLP、结构、知识、本地语言模型、专家路由与 TxGemma 已生成预测并保留证据。PerturbQA 和严格两阶段模型在覆盖检查阶段停止, base Gemma 与 LoRA 尚未运行。复现材料同时保留输入校验、样本与蛋白顺序、验证分组、随机种子、负对照、逐折指标和代码版本。

5.2 开源、依赖与合规

项目代码仓库为 github.com/Bananajia/goai-virtual-yeast。仓库在初赛提交截止前保持 private, 避免截止前出现代码或方案被复制, 也减少与其他队伍方案重复的风险。初赛截止后仓库转为 public, 公开 MiJiaoPredict、Metadata Ridge、配置、测试、实验注册表、匿名聚合指标和复现说明。受限原始数据、私有映射、逐蛋白历史预测、不可再分发的模型权重和凭据不进入公开仓库。外部数据库按各自许可使用, Qwen、Gemma 和 TxGemma 权重不随代码仓库再分发。

参考文献

- [1] Qian L, Zhou Z, Zhou P, et al. Towards the construction of a virtual yeast. *Nature*, 2026, 655: 59–70. doi:10.1038/s41586-026-10574-9.
- [2] Viñas Torné R, Wiatrak M, Piran Z, et al. Systema: a framework for evaluating genetic perturbation response prediction beyond systematic variation. *Nature Biotechnology*, 2026, 44:1050–1059; published online 25 August 2025. doi:10.1038/s41587-025-02777-8.
- [3] Morgan H L. The generation of a unique machine description for chemical structures. *Journal of Chemical Documentation*, 1965, 5(2):107–113.
- [4] Lotfollahi M, Klimovskaia Susmelj A, De Donno C, et al. Predicting cellular responses to complex perturbations in high-throughput screens. *Molecular Systems Biology*, 2023, 19:e11517.
- [5] Hetzel L, Böhm S, Kilbertus N, et al. Predicting cellular responses to novel drug perturbations at a single-cell resolution. *NeurIPS*, 2022, 35:26711–26722.
- [6] Szklarczyk D, Kirsch R, Koutrouli M, et al. The STRING database in 2023: protein–protein association networks and functional enrichment analyses. *Nucleic Acids Research*, 2023, 51:D638–D646.
- [7] Szklarczyk D, Santos A, von Mering C, et al. STITCH 5: augmenting protein–chemical interaction networks with tissue and affinity data. *Nucleic Acids Research*, 2016, 44:D380–D384.
- [8] The Gene Ontology Consortium. The Gene Ontology resource: enriching a GOLD mine. *Nucleic Acids Research*, 2021, 49:D325–D334.
- [9] Milacic M, Beavers D, Conley P, et al. The Reactome Pathway Knowledgebase 2024. *Nucleic Acids Research*, 2024, 52:D672–D678.
- [10] Peter J, De Chiara M, Friedrich A, et al. Genome evolution across 1,011 *Saccharomyces cerevisiae* isolates. *Nature*, 2018, 556:339–344.
- [11] Wang E, Schmidgall S, Jaeger P F, et al. TxGemma: Efficient and Agentic LLMs for Therapeutics. arXiv:2504.06196, 2025.
- [12] ProteomeXchange Consortium. PXD035050: The regulatory landscape of the yeast phosphoproteome –quantitative phosphoproteomic DIA data. ProteomeCentral dataset record.
- [13] The *Saccharomyces* Genome Database (SGD). Curated genomic, functional and literature resources for budding yeast; local snapshots and licenses recorded in the experiment manifests.
- [14] RDKit: Open-source cheminformatics. Local installation used for canonicalization, molecular descriptors and Morgan fingerprints; the exact version is recorded in the experiment manifest. <https://www.rdkit.org/>.
- [15] Arc Institute. Virtual Cell Challenge 2025 Wrap-Up: Winners and Reflections. 6 December 2025. <https://arcinstitute.org/news/virtual-cell-challenge-2025-wrap-up>.
- [16] Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 1970, 12(1):55–67. doi:10.1080/00401706.1970.10488634.
- [17] Hornik K, Stinchcombe M, White H. Multilayer feedforward networks are universal approximators. *Neural Networks*, 1989, 2(5):359–366. doi:10.1016/0893-6080(89)90020-8.
- [18] Yang A, Li A, Yang B, et al. Qwen3 Technical Report. arXiv:2505.09388, 2025. <https://arxiv.org/abs/2505.09388>.
- [19] Team Gemma. Gemma 3 Technical Report. arXiv:2503.19786, 2025. <https://arxiv.org/abs/2503.19786>.
- [20] Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. *ICLR*, 2017. <https://arxiv.org/abs/1701.06538>.
- [21] Jolliffe I T, Cadima J. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 2016, 374:20150202. doi:10.1098/rsta.2015.0202.
- [22] Shao Z, Wang P, Zhu Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv:2402.03300, 2024. <https://arxiv.org/abs/2402.03300>.